Articol bilingv (RO / EN) — versiune completă

Detectarea tehnicilor argumentative problematice: evaluare held-out · Șerban, G. F. · Partea I — Română / Part II — English

Detectarea tehnicilor argumentative problematice: evaluarea unei configurații înghețate şi a unui verificator de negație pe un set held-out

Șerban Gabriel Florin

Cercetător independent, Hannover, Germania · ORCID 0009-0000-2266-3356

Repository: github.com/politomorphism/politomorphism-defense · Versiune înghețată: explanation-v2-frozen

Statut: Preprint — raport preliminar, nerecenzat · noiembrie 2026

Rezumat

Detectarea automată a tehnicilor argumentative problematice presupune distingerea utilizărilor relevante de formulări care le seamănă lexical, dar nu realizează acelaşi mecanism argumentativ. Această distincție devine importantă în prezența negației, unde menționarea unei relații de echivalare nu implică afirmarea ei. Articolul prezintă evaluarea unei configurații de detecție, denumită v2, pe un set held-out de 120 de exemple, distinct de datele de dezvoltare şi construit de autor. Setul conține 60 de exemple pozitive şi 60 de controale, distribuite în şase clase. Criteriile de acceptare pentru v2, stabilite înaintea evaluării, au fost cel mult 22 de alarme false pe controale şi cel puțin 48 de detecții corecte pe exemplele pozitive. Configurația a înregistrat 16 alarme false şi 54 de detecții corecte, îndeplinind ambele criterii. Un verificator de negație aplicat ulterior predicțiilor salvate a eliminat cele şapte alarme false din subsetul de controale cu comparații negate, fără pierderea unor detecții corecte şi fără schimbări în afara clasei de echivalență; cele şapte predicții corectate au devenit respingeri corecte. Configurația combinată a înregistrat astfel nouă alarme false, menținând recall-ul la 90%. Rezultatele susțin îndeplinirea criteriilor prestabilite pe setul evaluat. Ele nu constituie validare independentă şi nu demonstrează generalizarea largă, deoarece datele şi etichetele de referință au fost construite de autor.

Cuvinte-cheie: detecție argumentativă, negație, alarme false, evaluare held-out, abținere, criterii prestabilite.

1. Introducere

Un sistem care detectează tehnici argumentative problematice trebuie să distingă între prezența efectivă a unei tehnici şi simpla apariție a unor expresii asociate cu aceasta. Un text poate menționa o comparație pentru a o respinge, poate descrie un argument fără a-l susține sau

poate utiliza o întrebare fără a realiza mecanismul vizat de detector. Prin urmare, evaluarea nu poate urmări exclusiv identificarea exemplelor pozitive. Ea trebuie să includă controale apropiate de acestea, capabile să evidențieze alarmele false şi limitele deciziei automate.

Lucrarea examinează două întrebări clare. Întrebarea 1: pe un set de evaluare separat de datele de dezvoltare, configurația înghețată v2 îndeplineşte criteriile de acceptare fixate dinainte — adică cel mult 22 de alarme false din 60 de controale şi cel puțin 48 de detecții corecte din 60 de exemple pozitive? Întrebarea 2: aplicat peste predicțiile deja salvate ale lui v2, un verificator orientat pe negație reduce alarmele false la controalele cu comparație negată, fără să piardă detecții corecte pe exemplele pozitive şi fără să modifice predicții din alte clase? Scopul evaluării este delimitat: verificarea unor criterii explicite pe date neutilizate la dezvoltarea configurației testate, nu demonstrarea unei competențe generale de analiză argumentativă.

2. Date şi protocol de evaluare

2.1. Cele şase clase (definiții operaționale)

Clasele sunt definite după taxonomia tehnicilor de propagandă (Da San Martino et al., 2020) şi după pragmatică: presupoziție (o afirmație contestată codificată ca deja dată); echivalență fabricată (două lucruri diferite afirmate ca identice); falsă dilemă (o alegere redusă la două opțiuni când există mai multe, sau prezentată ca închisă nejustificat); whataboutism (o critică deviată arătând spre adversar); întrebare retorică încărcată (o întrebare care îşi afirmă propriul răspuns); cauzalitate implicită (cauzalitate dedusă din simpla succesiune sau coincidență). Procedeul se numără doar dacă este asumat de autor: o comparație negată, citată şi contestată sau atenuată nu se numără.

2.2. Setul held-out

Setul evaluat conține 120 de exemple: 60 pozitive şi 60 de controale, şase clase cu câte zece exemple pozitive şi zece controale fiecare. Exemplele au fost construite de autor pentru evaluarea separată şi abordează teme diferite de cele utilizate în dezvoltare. Separarea exemplelor permite testarea configurației pe texte noi, dar nu asigură independența metodologică a datelor: selecția, construcția şi etichetarea lor provin din aceeaşi sursă. Etichetele sunt tratate drept referințe operaționale ale evaluării, nu drept judecăți confirmate prin consensul unor adnotatori independenți.

2.3. Configurația înghețată

Configurația v2 a fost fixată înaintea evaluării (model gpt-4o-mini, temperatură 0, tag explanation-v2-frozen). Pentru acceptare au fost stabilite două praguri: maximum 22 de alarme false pe cele 60 de controale; minimum 48 de detecții corecte pe cele 60 de exemple pozitive.

Acestea sunt praguri operaționale ale proiectului. Îndeplinirea lor nu echivalează cu un test de semnificație statistică şi nu implică adecvarea sistemului pentru orice context de utilizare.

2.4. Verificatorul de negație

Verificatorul urmăreşte reducerea alarmelor false în situațiile în care textul neagă relația de echivalare relevantă pentru detecție. El a fost evaluat prin aplicarea asupra predicțiilor salvate, permițând compararea rezultatelor înainte şi după verificare pe aceleaşi exemple, fără reclasificare. Criteriile prestabilite au fost: reducerea cu minimum 75% a alarmelor false din subsetul de comparații negate; pierderea a cel mult unei detecții corecte pe exemplele pozitive; zero schimbări ale predicțiilor în afara clasei de echivalență. Subsetul conține zece controale. Configurația de bază a produs şapte alarme false în acest subset, existând astfel erori observate asupra cărora intervenția putea avea un efect măsurabil.

2.5. Indicatori şi abținere

Recall-ul este raportul dintre numărul detecțiilor corecte şi cele 60 de exemple pozitive. Rata alarmelor false este raportul dintre controalele semnalate incorect şi totalul celor 60 de controale. Abținerea trebuie raportată separat de respingerea corectă: un control care nu produce alarmă nu este neapărat clasificat corect, deoarece sistemul poate refuza să decidă. În consecință, complementul ratei alarmelor false nu este interpretat drept rata respingerilor corecte.

3. Rezultate

3.1. Evaluarea configurației v2

Indicator	Criteriu prestabilit	Rezultat	Verdict
Alarme false pe controale	≤ 22/60	16/60	Îndeplinit
Detecții corecte pe pozitive	≥ 48/60	54/60	Îndeplinit

Rezultatele corespund unei rate a alarmelor false de 26,7% şi unui recall de 90%. Aceste valori susțin concluzia că v2 a trecut evaluarea operațională definită pentru acest set. Ele nu sunt suficiente, separat de alte dovezi, pentru a afirma robustețea în raport cu populații de texte sau contexte neexaminate.

3.2. Evaluarea verificatorului de negație

Indicator	Criteriu	Rezultat	Verdict
Reducere alarme false (subset comparații	≥ 75%	100%: de la 7 la 0	Îndeplinit

negate)			
Detecții corecte pierdute	≤ 1	0	Îndeplinit
Predicții schimbate în afara echivalenței	0	0	Îndeplinit

Reducerea de 100% se referă la cele şapte alarme false observate inițial; ea nu reprezintă o estimare a eficacității universale a verificatorului.

3.3. Rezultatul configurației combinate

Indicator	v2	v2 + verificator
Alarme false pe controale	16/60	9/60
Rata alarmelor false	26,7%	15,0%
Detecții corecte pe pozitive	54/60	54/60
Recall	90,0%	90,0%

La nivelul întregului set de controale, reducerea relativă a numărului de alarme false a fost de 43,8%, iar scăderea absolută a ratei acestora a fost de 11,7 puncte procentuale. Jurnalul predicțiilor individuale (coloana pred_final) confirmă că toate cele şapte alarme eliminate au devenit respingeri corecte (eticheta „niciuna”), nu abțineri; reducerea nu a fost, prin urmare, obținută prin refuzul de a decide.

4. Analiza erorilor şi a abținerilor

4.1. Presupoziția

Clasa presupoziției a înregistrat patru detecții corecte din zece exemple pozitive, adică un recall de 40% în această clasă. Rezultatul evidențiază o limită importantă pe care scorul agregat de 90% nu trebuie să o mascheze: performanța globală nu implică performanță uniformă între clase. Cauza, identificată din texte, este că presupozițiile sunt încastrate în grupuri nominale cu adjective încărcate, pe care ținta mai strictă a lui v2 le citeşte ca descriere, nu ca procedeu asumat.

4.2. Întrebarea retorică

Pe cele zece controale din clasa întrebării retorice nu au fost raportate alarme false, dar sistemul s-a abținut în toate cazurile. Acest comportament limitează semnalările incorecte, însă nu demonstrează capacitatea de a respinge corect controalele. Evaluarea trebuie să păstreze distincția dintre evitarea unei erori şi rezolvarea sarcinii.

4.3. Erorile rămase după verificare

Cele nouă alarme false rămase, după eticheta prezisă, sunt şase de falsă dilemă şi trei de cauzalitate implicită. Două dintre cele de cauzalitate implicită provin din perechi de whataboutism (cazurile W04 şi W08, unde conectorul „so we…” a fost citit drept cauzal), iar a noua este un control de cauzalitate implicită (C06). Niciuna nu ține de clasa echivalenței. Rezultatele indică faptul că intervenția asupra negației nu rezolvă toate sursele de alarmă falsă; ele motivează investigarea unor verificări suplimentare, dar nu demonstrează anticipat eficacitatea acestora.

5. Discuție

5.1. Ce susține evaluarea

Rezultatul principal este îndeplinirea unor criterii stabilite înaintea examinării rezultatelor pe setul held-out. Această ordine reduce riscul de a adapta retrospectiv definiția succesului la performanța observată. Comparația pe aceleaşi exemple arată că aplicarea verificatorului a fost asociată cu reducerea urmărită a alarmelor false, fără un cost observat în recall şi fără modificări în afara clasei vizate. Concluzia justificată este locală: intervenția a funcționat conform criteriilor pe acest set; nu demonstrează că verificatorul gestionează toate formele negației sau toate echivalările problematice.

5.2. Separarea de dezvoltare nu înseamnă independență

Un set poate fi separat de dezvoltare fără a fi independent de autorul sistemului. Alegerile de construcție pot reproduce aceleaşi definiții, stiluri şi presupuneri folosite la dezvoltare, chiar dacă exemplele şi temele sunt noi. Prin urmare, datele susțin o evaluare held-out construită de autor, nu o validare externă a sistemului.

5.3. Utilizarea ulterioară a setului

Examinarea erorilor pentru raportare nu invalidează rezultatul configurației înghețate. Totuşi, dacă aceste erori sunt folosite pentru modificarea sistemului, setul devine o resursă de dezvoltare pentru versiunea următoare, iar o nouă afirmație de performanță pe date neutilizate la ajustare va necesita un alt set de evaluare.

6. Limite

Evaluarea are următoarele limite principale. Date şi etichete construite de autor, fără confirmare prin adnotare umană independentă. Dimensiune redusă: cele zece exemple pe condiție şi clasă nu permit caracterizarea robustă a tuturor variațiilor relevante. Date construite, nu un eşantion reprezentativ de utilizare, astfel încât performanța observată nu estimează direct performanța într-un flux natural de texte. Distribuție echilibrată artificial, în timp ce frecvența tehnicilor în

utilizare poate fi diferită. Trasabilitate necesară: reproductibilitatea presupune publicarea versiunii evaluate, a protocolului, a etichetelor şi a predicțiilor individuale, toate disponibile în repository. Lipsa adnotatorilor externi nu împiedică raportarea rezultatului, dar limitează interpretarea etichetelor şi a performanței măsurate față de acestea.

7. Direcții viitoare

Sunt justificate trei direcții. Prima este evaluarea etichetelor de către adnotatori externi, atunci când resursele o permit, pentru a clarifica ambiguitățile şi gradul de acord asupra definițiilor operaționale. A doua este extinderea evaluării la date colectate independent şi la texte din utilizare naturală, păstrând separarea dintre dezvoltare şi testare. A treia este investigarea erorilor rămase, în special în clasele falsei dileme şi presupoziției; orice modificare bazată pe erorile actuale trebuie evaluată ulterior pe alte date, fără a reutiliza acest set ca dovadă neatinsă de validare.

8. Concluzii

Configurația v2 a îndeplinit criteriile prestabilite pe setul held-out: 16 alarme false pe 60 de controale şi 54 de detecții corecte pe 60 de exemple pozitive. Verificatorul de negație a îndeplinit, la rândul său, criteriile stabilite: a eliminat cele şapte alarme false din subsetul de comparații negate, fără pierderea unor detecții corecte şi fără schimbări în afara clasei de echivalență, iar corecțiile au devenit respingeri corecte. Configurația combinată a redus rata alarmelor false de la 26,7% la 15%, menținând recall-ul la 90%. Aceste rezultate documentează îndeplinirea criteriilor de acceptare pe un set separat de dezvoltare, construit de autor. Nu demonstrează generalizarea largă şi nu constituie validare independentă. Contribuția constă într-un rezultat delimitat şi verificabil: o intervenție țintită a redus erorile urmărite pe exemple noi, fără regresii observate în detecția pozitivă, în condițiile şi limitele protocolului descris.

Bibliografie

Cohen, J. (1960). A coefficient of agreement for nominal scales. Educational and Psychological Measurement, 20(1), 37–46.

Cronbach, L. J., & Meehl, P. E. (1955). Construct validity in psychological tests. Psychological Bulletin, 52(4), 281–302.

Da San Martino, G., Barrón-Cedeño, A., Wachsmuth, H., Petrov, R., & Nakov, P. (2020). SemEval-2020 Task 11: Detection of propaganda techniques in news articles. Proceedings of the 14th Workshop on Semantic Evaluation, 1377–1414.

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1), 159–174.

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108.

Șerban, G. F. (2026). Working Papers I–III in Computational Political Anthropology. Zenodo. https://doi.org/10.5281/zenodo.23884579

Detecting Problematic Argumentative Techniques: Evaluating a Frozen Configuration and a Negation Verifier on a Held-Out Dataset

Șerban Gabriel Florin

Independent Researcher, Hannover, Germany · ORCID 0009-0000-2266-3356

Repository: github.com/politomorphism/politomorphism-defense · Frozen version: explanation-v2-frozen

Status: Preprint — preliminary report, not peer-reviewed · November 2026

Abstract

Automatically detecting problematic argumentative techniques requires distinguishing relevant instances from expressions that resemble them lexically but do not instantiate the same argumentative mechanism. This distinction is particularly important in the presence of negation, where mentioning an equivalence relation does not necessarily amount to asserting it. This article evaluates a detection configuration, designated v2, on an author-constructed held-out dataset of 120 examples, separate from the development data. The dataset contains 60 positive examples and 60 controls across six classes. The acceptance criteria established before evaluation required no more than 22 false alarms on controls and at least 48 correct detections on positive examples. The configuration produced 16 false alarms and 54 correct detections, meeting both criteria. A negation verifier subsequently applied to the saved predictions eliminated all seven false alarms in the subset of controls involving negated comparisons, without losing any correct positive detections or changing predictions outside the equivalence class; the seven corrected predictions became correct rejections. The combined configuration therefore produced nine false alarms while maintaining 90% recall. These results establish that the frozen configuration met the predefined acceptance criteria on the evaluated dataset. They do not constitute independent validation or demonstrate broad generalization, because the dataset and reference labels were constructed by the author.

Keywords: argumentative technique detection, negation, false alarms, held-out evaluation, abstention, predefined acceptance criteria.

1. Introduction

A system that detects problematic argumentative techniques must distinguish between an actual instance of a technique and the mere occurrence of expressions associated with it. A text may mention a comparison in order to reject it, describe an argument without endorsing it, or use a question without instantiating the mechanism targeted by the detector. Evaluation must therefore examine more than the identification of positive examples. It must also include closely related controls capable of exposing false alarms and limitations in automated decision-making.

This study addresses two clear questions. Question 1: on an evaluation set separate from the development data, does the frozen v2 configuration meet the pre-set acceptance criteria — that is, at most 22 false alarms out of 60 controls and at least 48 correct detections out of 60 positive examples? Question 2: applied on top of v2's already-saved predictions, does a negation-focused verifier reduce false alarms on negated-comparison controls, without losing correct detections on the positive examples and without changing predictions in other classes? The evaluation has a bounded objective: to test explicit criteria on examples not used to develop the evaluated configuration, rather than to demonstrate a general capacity for argumentative analysis.

2. Data and Evaluation Protocol

2.1. The six classes (operational definitions)

The classes follow the taxonomy of propaganda techniques (Da San Martino et al., 2020) and pragmatics: presupposition (a contested claim encoded as already given); manufactured equivalence (two unlike things asserted to be identical); false dilemma (a choice collapsed to two options when more exist, or unjustifiably presented as closed); whataboutism (a criticism deflected by pointing at the opponent); loaded rhetorical question (a question that asserts its own answer); implied causation (causation inferred from mere sequence or co-occurrence). A device is counted only if the author endorses it: a comparison that is negated, quoted and contested, or hedged does not count.

2.2. Held-out dataset

The evaluation dataset contains 120 examples: 60 positive examples and 60 controls, six classes each containing ten positive examples and ten controls. The author constructed the examples for a separate evaluation using topics different from those represented in development. This separation permits testing on new texts, but it does not establish methodological independence: example selection, construction, and labeling originate from the same source. The labels are therefore treated as the evaluation's operational references, not as judgments confirmed through agreement among independent annotators.

2.3. Frozen configuration

The v2 configuration was fixed before evaluation (model gpt-4o-mini, temperature 0, tag explanation-v2-frozen). Two acceptance thresholds were established: no more than 22 false alarms among the 60 controls; at least 48 correct detections among the 60 positive examples. These are project-specific operational thresholds. Meeting them is not equivalent to passing a statistical significance test and does not imply suitability for every application.

2.4. Negation verifier

The verifier targets false alarms in cases where a text negates the equivalence relation relevant to detection. It was evaluated by applying it to saved predictions, enabling a paired comparison before and after verification on the same examples, without re-classification. The predefined criteria were: a reduction of at least 75% in false alarms within the negated-comparison subset; the loss of no more than one correct positive detection; no prediction changes outside the equivalence class. The subset contains ten controls. The baseline configuration produced seven false alarms within this subset, providing observed errors against which the intervention's effect could be measured.

2.5. Metrics and abstention

Recall is the number of correct detections divided by the 60 positive examples. The false-alarm rate is the number of incorrectly flagged controls divided by the 60 controls. Abstention must be distinguished from correct rejection: a control that does not trigger an alarm is not necessarily correctly classified, because the system may decline to decide. Consequently, the complement of the false-alarm rate is not interpreted here as the correct-rejection rate.

3. Results

3.1. Evaluation of v2

Metric	Predefined criterion	Result	Outcome
False alarms on controls	≤ 22/60	16/60	Met
Correct detections on positives	≥ 48/60	54/60	Met

These results correspond to a 26.7% false-alarm rate and 90% recall. They support the conclusion that v2 passed the operational evaluation defined for this dataset. Without additional evidence, they do not establish robustness across unexamined text populations or contexts.

3.2. Evaluation of the negation verifier

Metric	Predefined criterion	Result	Outcome
False-alarm reduction (negated-comparison subset)	≥ 75%	100%: from 7 to 0	Met
Correct positive detections lost	≤ 1	0	Met
Predictions changed outside equivalence	0	0	Met

The 100% reduction refers to the seven false alarms initially observed; it is not an estimate of the verifier's universal effectiveness.

3.3. Combined configuration

Metric	v2	v2 + verifier
False alarms on controls	16/60	9/60
False-alarm rate	26.7%	15.0%
Correct detections on positives	54/60	54/60
Recall	90.0%	90.0%

Across the full control set, the relative reduction in the number of false alarms was 43.8%, and the absolute decrease in the false-alarm rate was 11.7 percentage points. The individual-prediction log (the pred_final column) confirms that all seven eliminated alarms became correct rejections (the label "none"), not abstentions; the reduction was therefore not obtained by declining to decide.

4. Error and Abstention Analysis

4.1. Presupposition

The presupposition class yielded four correct detections among ten positive examples, corresponding to 40% recall within that class. This identifies a substantial limitation that should not be obscured by the aggregate recall of 90%: strong overall performance does not imply uniform performance across classes. The cause, identified from the texts, is that the presuppositions are embedded in noun phrases with loaded adjectives, which v2's stricter target reads as description rather than as a device the author endorses.

4.2. Rhetorical questions

No false alarms were reported among the ten rhetorical-question controls, but the system abstained on all ten. This behavior limits incorrect flagging, but it does not demonstrate an ability to reject controls correctly. Evaluation must preserve the distinction between avoiding an error and resolving the classification task.

4.3. Errors remaining after verification

By predicted label, the nine remaining false alarms are six false dilemmas and three implied causations. Two of the implied-causation cases come from whataboutism pairs (W04 and W08, where the “so we…” connective was read as causal), and the ninth is an implied-causation control (C06). None belongs to the equivalence class. The results show that the negation intervention does not address every source of false alarms; they motivate investigating additional verification mechanisms, but do not establish those mechanisms’ effectiveness in advance.

5. Discussion

5.1. What the evaluation supports

The primary finding is that the configuration met criteria established before the held-out results were examined. This ordering reduces the risk of retrospectively adapting the definition of success to the observed performance. The paired comparison also shows that applying the verifier produced the targeted reduction in false alarms, with no observed cost to recall and no changes outside the targeted class. The warranted conclusion is local: the intervention worked according to the predefined criteria on this dataset; it does not demonstrate that the verifier handles every form of negation or every problematic equivalence relation.

5.2. Separation from development is not independence

A dataset can be separate from development without being independent of the system’s author. Construction choices may reproduce the definitions, styles, and assumptions used during development, even when the examples and topics are new. The evidence therefore supports an author-constructed held-out evaluation, not external validation of the system.

5.3. Subsequent use of the dataset

Examining errors for reporting purposes does not invalidate the result obtained by the frozen configuration. However, if those errors are used to modify the system, the dataset becomes a development resource for the next version, and any subsequent claim about performance on data not used for adjustment would require another evaluation dataset.

6. Limitations

The evaluation has the following principal limitations. Author-constructed data and labels, without confirmation through independent human annotation. Small sample size: ten examples per condition and class do not permit robust characterization of all relevant variation. Constructed examples rather than a representative usage sample, so observed performance

does not directly estimate performance on naturally occurring text streams. Artificially balanced class distribution, whereas the prevalence of the targeted techniques may differ in actual use. Traceability requirement: reproducibility requires access to the evaluated version, protocol, labels, and individual predictions, all available in the repository. The absence of external annotators does not prevent reporting these results; it does, however, limit the interpretation of the reference labels and of performance measured against them.

7. Future Work

Three directions are warranted. First, external annotators could assess the reference labels when resources permit, clarifying ambiguous cases and measuring agreement on the operational definitions. Second, evaluation should be extended to independently collected data and naturally occurring texts while preserving the separation between development and testing. Third, the remaining errors warrant investigation, particularly in the false-dilemma and presupposition classes; any modifications informed by the present errors should subsequently be evaluated on different data, rather than reusing this dataset as untouched validation evidence.

8. Conclusion

The v2 configuration met the predefined criteria on the held-out dataset, producing 16 false alarms among 60 controls and 54 correct detections among 60 positive examples. The negation verifier also met its predefined criteria: it eliminated the seven false alarms in the negated-comparison subset without losing correct positive detections or changing predictions outside the equivalence class, and the corrections became correct rejections. The combined configuration reduced the false-alarm rate from 26.7% to 15.0% while maintaining 90% recall. These results document that the acceptance criteria were met on an author-constructed dataset separate from development. They do not demonstrate broad generalization or constitute independent validation. The contribution is a bounded, verifiable finding: a targeted intervention reduced the intended errors on new examples without observed regression in positive detection, under the conditions and limitations of the reported protocol.

References

Cohen, J. (1960). A coefficient of agreement for nominal scales. Educational and Psychological Measurement, 20(1), 37–46.

Cronbach, L. J., & Meehl, P. E. (1955). Construct validity in psychological tests. Psychological Bulletin, 52(4), 281–302.

Da San Martino, G., Barrón-Cedeño, A., Wachsmuth, H., Petrov, R., & Nakov, P. (2020). SemEval-2020 Task 11: Detection of propaganda techniques in news articles. Proceedings of the 14th Workshop on Semantic Evaluation, 1377–1414.

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1), 159–174.

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108.

Șerban, G. F. (2026). Working Papers I–III in Computational Political Anthropology. Zenodo. https://doi.org/10.5281/zenodo.23884579