Detectarea tehnicilor argumentative problematice: evaluarea unei configurații înghețate şi a unui verificator de negație pe un set held-out

Șerban Gabriel Florin

Cercetător independent, Hannover, Germania · ORCID 0009-0000-2266-3356

Repository: github.com/politomorphism/politomorphism-defense · Versiune înghețată: explanation-v2-frozen

Statut: Preprint — raport preliminar, nerecenzat · noiembrie 2026

Rezumat

Detectarea automată a tehnicilor argumentative problematice presupune distingerea utilizărilor relevante de formulări care le seamănă lexical, dar nu realizează acelaşi mecanism argumentativ. Această distincție devine importantă în prezența negației, unde menționarea unei relații de echivalare nu implică afirmarea ei. Articolul prezintă evaluarea unei configurații de detecție, denumită v2, pe un set held-out de 120 de exemple, distinct de datele de dezvoltare şi construit de autor. Setul conține 60 de exemple pozitive şi 60 de controale, distribuite în şase clase. Criteriile de acceptare pentru v2, stabilite înaintea evaluării, au fost cel mult 22 de alarme false pe controale şi cel puțin 48 de detecții corecte pe exemplele pozitive. Configurația a înregistrat 16 alarme false şi 54 de detecții corecte, îndeplinind ambele criterii. Un verificator de negație aplicat ulterior predicțiilor salvate a eliminat cele şapte alarme false din subsetul de controale cu comparații negate, fără pierderea unor detecții corecte şi fără schimbări în afara clasei de echivalență; cele şapte predicții corectate au devenit respingeri corecte. Configurația combinată a înregistrat astfel nouă alarme false, menținând recall-ul la 90%. Rezultatele susțin îndeplinirea criteriilor prestabilite pe setul evaluat. Ele nu constituie validare independentă şi nu demonstrează generalizarea largă, deoarece datele şi etichetele de referință au fost construite de autor.

Cuvinte-cheie: detecție argumentativă, negație, alarme false, evaluare held-out, abținere, criterii prestabilite.

1. Introducere

Un sistem care detectează tehnici argumentative problematice trebuie să distingă între prezența efectivă a unei tehnici şi simpla apariție a unor expresii asociate cu aceasta. Un text poate menționa o comparație pentru a o respinge, poate descrie un argument fără a-l susține sau

poate utiliza o întrebare fără a realiza mecanismul vizat de detector. Prin urmare, evaluarea nu poate urmări exclusiv identificarea exemplelor pozitive. Ea trebuie să includă controale apropiate de acestea, capabile să evidențieze alarmele false şi limitele deciziei automate.

Lucrarea examinează două întrebări clare. Întrebarea 1: pe un set de evaluare separat de datele de dezvoltare, configurația înghețată v2 îndeplineşte criteriile de acceptare fixate dinainte — adică cel mult 22 de alarme false din 60 de controale şi cel puțin 48 de detecții corecte din 60 de exemple pozitive? Întrebarea 2: aplicat peste predicțiile deja salvate ale lui v2, un verificator orientat pe negație reduce alarmele false la controalele cu comparație negată, fără să piardă detecții corecte pe exemplele pozitive şi fără să modifice predicții din alte clase? Scopul evaluării este delimitat: verificarea unor criterii explicite pe date neutilizate la dezvoltarea configurației testate, nu demonstrarea unei competențe generale de analiză argumentativă.

2. Date şi protocol de evaluare

2.1. Cele şase clase (definiții operationale)

Clasele sunt definite după taxonomia tehnicilor de propagandă (Da San Martino et al., 2020) şi după pragmatică: presupoziție (o afirmație contestată codificată ca deja dată); echivalență fabricată (două lucruri diferite afirmate ca identice); falsă dilemă (o alegere redusă la două opțiuni când există mai multe, sau prezentată ca închisă nejustificat); whataboutism (o critică deviată arătând spre adversar); întrebare retorică încărcată (o întrebare care îşi afirmă propriul răspuns); cauzalitate implicită (cauzalitate dedusă din simpla succesiune sau coincidență). Procedeul se numără doar dacă este asumat de autor: o comparație negată, citată şi contestată sau atenuată nu se numără.

2.2. Setul held-out

Setul evaluat conține 120 de exemple: 60 pozitive şi 60 de controale, şase clase cu câte zece exemple pozitive şi zece controale fiecare. Exemplele au fost construite de autor pentru evaluarea separată şi abordează teme diferite de cele utilizate în dezvoltare. Separarea exemplelor permite testarea configurației pe texte noi, dar nu asigură independența metodologică a datelor: selecția, construcția şi etichetarea lor provin din aceeaşi sursă. Etichetele sunt tratate drept referințe operaționale ale evaluării, nu drept judecăți confirmate prin consensul unor adnotatori independenți.

2.3. Configurația înghețată

Configurația v2 a fost fixată înaintea evaluării (model gpt-4o-mini, temperatură 0, tag explanation-v2-frozen). Pentru acceptare au fost stabilite două praguri: maximum 22 de alarme false pe cele 60 de controale; minimum 48 de detecții corecte pe cele 60 de exemple pozitive.

Acestea sunt praguri operaționale ale proiectului. Îndeplinirea lor nu echivalează cu un test de semnificație statistică şi nu implică adecvarea sistemului pentru orice context de utilizare.

2.4. Verificatorul de negație

Verificatorul urmăreşte reducerea alarmelor false în situațiile în care textul neagă relația de echivalare relevantă pentru detecție. El a fost evaluat prin aplicarea asupra predicțiilor salvate, permițând compararea rezultatelor înainte şi după verificare pe aceleaşi exemple, fără reclasificare. Criteriile prestabilite au fost: reducerea cu minimum 75% a alarmelor false din subsetul de comparații negate; pierderea a cel mult unei detecții corecte pe exemplele pozitive; zero schimbări ale predicțiilor în afara clasei de echivalență. Subsetul conține zece controale. Configurația de bază a produs şapte alarme false în acest subset, existând astfel erori observate asupra cărora intervenția putea avea un efect măsurabil.

2.5. Indicatori şi abținere

Recall-ul este raportul dintre numărul detecțiilor corecte şi cele 60 de exemple pozitive. Rata alarmelor false este raportul dintre controalele semnalate incorect şi totalul celor 60 de controale. Abținerea trebuie raportată separat de respingerea corectă: un control care nu produce alarmă nu este neapărat clasificat corect, deoarece sistemul poate refuza să decidă. În consecință, complementul ratei alarmelor false nu este interpretat drept rata respingerilor corecte.

3. Rezultate

3.1. Evaluarea configurației v2

Indicator	Criteriu prestabilit	Rezultat	Verdict
Alarme false pe controale	≤ 22/60	16/60	Îndeplinit
Detecții corecte pe pozitive	≥ 48/60	54/60	Îndeplinit

Rezultatele corespund unei rate a alarmelor false de 26,7% şi unui recall de 90%. Aceste valori susțin concluzia că v2 a trecut evaluarea operațională definită pentru acest set. Ele nu sunt suficiente, separat de alte dovezi, pentru a afirma robustețea în raport cu populații de texte sau contexte neexaminate.

3.2. Evaluarea verificatorului de negație

Indicator	Criteriu	Rezultat	Verdict
Reducere alarme false (subset comparații	≥ 75%	100%: de la 7 la 0	Îndeplinit

negate)			
Detecții corecte pierdute	≤ 1	0	Îndeplinit
Predicții schimbate în afara echivalenței	0	0	Îndeplinit

Reducerea de 100% se referă la cele şapte alarme false observate inițial; ea nu reprezintă o estimare a eficacității universale a verificatorului.

3.3. Rezultatul configurației combinate

Indicator	v2	v2 + verificator
Alarme false pe controale	16/60	9/60
Rata alarmelor false	26,7%	15,0%
Detecții corecte pe pozitive	54/60	54/60
Recall	90,0%	90,0%

La nivelul întregului set de controale, reducerea relativă a numărului de alarme false a fost de 43,8%, iar scăderea absolută a ratei acestora a fost de 11,7 puncte procentuale. Jurnalul predicțiilor individuale (coloana pred_final) confirmă că toate cele şapte alarme eliminate au devenit respingeri corecte (eticheta „niciuna”), nu abțineri; reducerea nu a fost, prin urmare, obținută prin refuzul de a decide.

4. Analiza erorilor şi a abținerilor

4.1. Presupoziția

Clasa presupoziției a înregistrat patru detecții corecte din zece exemple pozitive, adică un recall de 40% în această clasă. Rezultatul evidențiază o limită importantă pe care scorul agregat de 90% nu trebuie să o mascheze: performanța globală nu implică performanță uniformă între clase. Cauza, identificată din texte, este că presupozițiile sunt încastrate în grupuri nominale cu adjective încărcate, pe care ținta mai strictă a lui v2 le citeşte ca descriere, nu ca procedeu asumat.

4.2. Întrebarea retorică

Pe cele zece controale din clasa întrebării retorice nu au fost raportate alarme false, dar sistemul s-a abținut în toate cazurile. Acest comportament limitează semnalările incorecte, însă nu demonstrează capacitatea de a respinge corect controalele. Evaluarea trebuie să păstreze distincția dintre evitarea unei erori şi rezolvarea sarcinii.

4.3. Erorile rămase după verificare

Cele nouă alarme false rămase, după eticheta prezisă, sunt şase de falsă dilemă şi trei de cauzalitate implicită. Două dintre cele de cauzalitate implicită provin din perechi de whataboutism (cazurile W04 şi W08, unde conectorul „so we…” a fost citit drept cauzal), iar a noua este un control de cauzalitate implicită (C06). Niciuna nu ține de clasa echivalenței. Rezultatele indică faptul că intervenția asupra negației nu rezolvă toate sursele de alarmă falsă; ele motivează investigarea unor verificări suplimentare, dar nu demonstrează anticipat eficacitatea acestora.

5. Discuție

5.1. Ce susține evaluarea

Rezultatul principal este îndeplinirea unor criterii stabilite înaintea examinării rezultatelor pe setul held-out. Această ordine reduce riscul de a adapta retrospectiv definiția succesului la performanța observată. Comparația pe aceleaşi exemple arată că aplicarea verificatorului a fost asociată cu reducerea urmărită a alarmelor false, fără un cost observat în recall şi fără modificări în afara clasei vizate. Concluzia justificată este locală: intervenția a funcționat conform criteriilor pe acest set; nu demonstrează că verificatorul gestionează toate formele negației sau toate echivalările problematice.

5.2. Separarea de dezvoltare nu înseamnă independență

Un set poate fi separat de dezvoltare fără a fi independent de autorul sistemului. Alegerile de construcție pot reproduce aceleaşi definiții, stiluri şi presupuneri folosite la dezvoltare, chiar dacă exemplele şi temele sunt noi. Prin urmare, datele susțin o evaluare held-out construită de autor, nu o validare externă a sistemului.

5.3. Utilizarea ulterioară a setului

Examinarea erorilor pentru raportare nu invalidează rezultatul configurației înghețate. Totuşi, dacă aceste erori sunt folosite pentru modificarea sistemului, setul devine o resursă de dezvoltare pentru versiunea următoare, iar o nouă afirmație de performanță pe date neutilizate la ajustare va necesita un alt set de evaluare.

6. Limite

Evaluarea are următoarele limite principale. Date şi etichete construite de autor, fără confirmare prin adnotare umană independentă. Dimensiune redusă: cele zece exemple pe condiție şi clasă nu permit caracterizarea robustă a tuturor variațiilor relevante. Date construite, nu un eşantion reprezentativ de utilizare, astfel încât performanța observată nu estimează direct performanța într-un flux natural de texte. Distribuție echilibrată artificial, în timp ce frecvența tehnicilor în

utilizare poate fi diferită. Trasabilitate necesară: reproductibilitatea presupune publicarea versiunii evaluate, a protocolului, a etichetelor şi a predicțiilor individuale, toate disponibile în repository. Lipsa adnotatorilor externi nu împiedică raportarea rezultatului, dar limitează interpretarea etichetelor şi a performanței măsurate față de acestea.

7. Direcții viitoare

Sunt justificate trei direcții. Prima este evaluarea etichetelor de către adnotatori externi, atunci când resursele o permit, pentru a clarifica ambiguitățile şi gradul de acord asupra definițiilor operaționale. A doua este extinderea evaluării la date colectate independent şi la texte din utilizare naturală, păstrând separarea dintre dezvoltare şi testare. A treia este investigarea erorilor rămase, în special în clasele falsei dileme şi presupoziției; orice modificare bazată pe erorile actuale trebuie evaluată ulterior pe alte date, fără a reutiliza acest set ca dovadă neatinsă de validare.

8. Concluzii

Configurația v2 a îndeplinit criteriile prestabilite pe setul held-out: 16 alarme false pe 60 de controale şi 54 de detecții corecte pe 60 de exemple pozitive. Verificatorul de negație a îndeplinit, la rândul său, criteriile stabilite: a eliminat cele şapte alarme false din subsetul de comparații negate, fără pierderea unor detecții corecte şi fără schimbări în afara clasei de echivalență, iar corecțiile au devenit respingeri corecte. Configurația combinată a redus rata alarmelor false de la 26,7% la 15%, menținând recall-ul la 90%. Aceste rezultate documentează îndeplinirea criteriilor de acceptare pe un set separat de dezvoltare, construit de autor. Nu demonstrează generalizarea largă şi nu constituie validare independentă. Contribuția constă într-un rezultat delimitat şi verificabil: o intervenție țintită a redus erorile urmărite pe exemple noi, fără regresii observate în detecția pozitivă, în condițiile şi limitele protocolului descris.

Bibliografie

Cohen, J. (1960). A coefficient of agreement for nominal scales. Educational and Psychological Measurement, 20(1), 37–46.

Cronbach, L. J., & Meehl, P. E. (1955). Construct validity in psychological tests. Psychological Bulletin, 52(4), 281–302.

Da San Martino, G., Barrón-Cedeño, A., Wachsmuth, H., Petrov, R., & Nakov, P. (2020). SemEval-2020 Task 11: Detection of propaganda techniques in news articles. Proceedings of the 14th Workshop on Semantic Evaluation, 1377–1414.

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1), 159–174.

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108.

Șerban, G. F. (2026). Working Papers I–III in Computational Political Anthropology. Zenodo. https://doi.org/10.5281/zenodo.23884579