Clasificatorul v2: analiză de erori

Abținere și conștiință a negației pe benchmark-ul de perechi contrastive (v0.3, 60 de perechi)

Șerban, G. F. · noiembrie 2026

Ce s-a testat

Clasificatorul v1 numea procedeul bine când exista (0,917) dar inventa un procedeu pe text simplu în 65% din cazuri. Versiunea v2 adaugă două lucruri: dreptul de a răspunde „niciuna” sau „dovezi insuficiente”, și o țintă declarată — se numește doar procedeul pe care autorul îl asumă, nu orice structură care apare (o comparație negată, citată sau atenuată nu se numără). Această notă raportează ce a schimbat v2 pe aceleași 60 de perechi și de ce, cu textele erorilor.

Rezultatul complet

Indicator	v1	v2
Alarme false pe controale	39/60 — 65%	16/60 — 26,7%
Controale corect „niciuna”	21/60 — 35%	25/60 — 41,7%
Abțineri pe controale	0/60	19/60 — 31,7%
Pozitive — tehnica corectă	55/60 — 91,7%	51/60 — 85%
Recall-ul detecției pe pozitive	57/60 — 95%	52/60 — 86,7%
Pozitive clasificate „niciuna”	3/60	8/60 — 13,3%
Abțineri pe pozitive	0/60	0/60

Alarmele false scad cu 38 de puncte. Dar recall-ul detecției pierde 8 puncte și tehnica corectă pierde 7. Îmbunătățire defensivă reală, cu un cost real de detecție.

Observația decisivă: corectitudinea exactă nu crește. v1 are 55+21 = 76/120 răspunsuri exact corecte; v2 are 51+25 = 76/120 — ambele 63,3%, cu abținerea necreditată. v2 nu este mai corect: redistribuie erorile, schimbând acuzații false pe abțineri și pe ratări de presupoziție. Pentru un instrument defensiv o abținere este preferabilă unei acuzații false, deci v2 rămâne de preferat — dar nu se poate pretinde o creștere a corectitudinii.

De ce — trei mecanisme, din textele erorilor

1. Presupoziția încastrată, ratată (8/8). Toate cele opt ratări au presupoziția ascunsă într-un grup nominal cu adjectiv încărcat; autorul pare că descrie, iar judecata contestată e strecurată în fundal. Paradoxal, ținta mai strictă a lui v2 („doar ce autorul asumă”) a împins modelul să le rateze, fiindcă structural autorul asumă propoziția-cadru, nu adjectivul presupus. Exemple:

„Residents keep protesting the council's FAILED housing plan.” · „Journalists exposed the senator's SECRET foreign payments.” · „The union condemned the factory's UNFAIR dismissal of workers.”

2. Comparația negată, tot semnalată (6/6). Toate cele șase alarme false pe echivalență sunt comparații explicit negate; modelul le etichetează drept echivalență fabricată în ciuda negației și a instrucțiunii de a o ignora. Instrucțiunea generală nu a funcționat aici. Exemple:

„The new data law lets the state watch citizens, UNLIKE the way past dictatorships watched citizens.” · „Raising the retirement age takes money from workers, BUT NOT the way a thief takes money.”

3. Trei opțiuni citite ca falsă dilemă (8/8). Toate cele opt alarme false pe falsă dilemă sunt propoziții cu trei opțiuni; modelul vede cadrul de enumerare și tema binară, dar nu numără opțiunile. Exemple:

„We could pass the security bill now, AMEND it, OR weigh the danger.” · „The mayor could resign, apologize, OR stay while the city continues.”

Concluzia care schimbă direcția

Cele trei erori nu sunt despre arhitectură, ci despre raționament compozițional: sfera negației, numărarea opțiunilor, presupoziția încastrată. Prin urmare, nici poarta în doi pași (detecție apoi explicație) nu le-ar repara singură — detectorul din față ar întâlni aceleași comparații negate și aceleași propoziții cu trei opțiuni. O instrucțiune generală nu ajunge. Reparația potrivită este verificări țintite pe fiecare mecanism, nu o nouă ajustare globală.

Prioritatea este negația. A eticheta drept „face o comparație cu dictatura” pe cineva care spune explicit „nu ca o dictatură” este tocmai citirea greșită care transformă un detector într-o unealtă de învinovățire. Pasul următor imediat este o sub-verificare dedicată a sferei negației, testată pe exact aceste cazuri.

Materiale

Predicțiile brute v2 (contrastive_pairs_v3_v2_predictions.csv), clasificatorul v2 (16_classifier_v2_abstention.py) și setul de controale dificile (hard_controls.csv) sunt în depozit. Textele complete ale erorilor citate mai sus sunt în contrastive_pairs_v3.csv.