Numirea procedeului: de la detecție la explicație

Notă tehnică — clasificatorul de tehnică pe benchmark-ul de perechi contrastive (v0.3, 60 de perechi)

Șerban, G. F. · noiembrie 2026

Ce s-a testat

Lucrările I–III scorează o propoziție ca manipulativă sau simplă. Un strat de audit defensiv are nevoie de mai mult decât un scor: trebuie să spună care procedeu este prezent, pentru ca un cititor uman să vadă mecanismul. Această notă documentează primul pas al brațului de explicație: un clasificator care numește procedeul. Fiindcă benchmark-ul are doar zece exemple pe tehnică — prea puține pentru a antrena fără supraînvățare un clasificator cu șase clase — abordarea este zero-shot: un model care cunoaște deja definițiile (OpenAI gpt-4o-mini) primește cele șase definiții publice în prompt și trebuie să aleagă o singură etichetă dintre cele șase tehnici sau „niciuna”. Cei 120 de membri (60 manipulativi, 60 de control) au fost prezentați fiecare singur; adevărul de referință este tehnica fiecărui membru manipulativ și „niciuna” pentru fiecare control.

Rezultatul în două fețe

Când un procedeu este prezent, modelul îl numește bine. Pe cei 60 de membri manipulativi, acuratețea de numire este 0,917 (55 din 60). Patru din șase tehnici sunt perfecte — echivalența fabricată, falsa dilemă, whataboutismul și întrebarea retorică încărcată, toate 10 din 10. Presupoziția este cea mai slabă (0,70; trei ratări etichetate „niciuna”, procedeul fiind cel mai subtil), iar cauzalitatea implicită 0,80 (două confuzii cu falsa dilemă, la perechile de tip „pantă alunecoasă”, structural la graniță). Ca explicație, deci, atunci când are ce explica, instrumentul funcționează.

Dar pe propozițiile simple, instrumentul inventează un procedeu în 65% din cazuri.

Pe cei 60 de membri de control, modelul spune corect „niciuna” doar în 21 de cazuri (0,35); în restul de 39 (rată de procedeu-fals 0,65) atribuie o tehnică unui text cinstit. Cel mai clar la echivalența fabricată: controalele păstrează cuvintele încărcate („dictatură”, „hoț”) dar neagă comparația, iar modelul vede cuvintele, ratează negația și etichetează greșit 10 din 10. Pentru o unealtă care combate manipularea, aceasta este slăbiciunea critică: un detector cu prea multe alarme false devine el însuși un instrument de învinovățire nedreaptă.

Cifre

Măsură	Valoare	Interpretare
Numirea tehnicii (membri manipulativi)	0,917 (55/60)	bun — explică bine când există procedeu
Control etichetat corect „niciuna”	0,350 (21/60)	slab — specificitate mică
Rată de procedeu-fals (pe control)	0,650 (39/60)	critic — prea multe alarme false
Presupoziție (recall)	0,70	cel mai subtil procedeu
Cauzalitate implicită (recall)	0,80	confuzii cu falsa dilemă
Celelalte patru tehnici (recall)	1,00	perfect

Lecția de arhitectură

Experimentul arată de ce instrumentul nu trebuie să ceară modelului totul dintr-o singură mișcare. Clasificatorul de azi a sărit direct la numirea tehnicii pe orice propoziție, de aceea inventează pe text simplu. Soluția este un design în doi pași. Întâi detecția — „este manipulativ sau simplu?” — unde modelul contextual al programului este puternic (acuratețe pe pereche 0,917). Abia ceea ce trece de această poartă ajunge la pasul al doilea, numirea procedeului, unde modelul este iarăși bun (0,917). Poarta oprește alarmele false înainte de etichetare. Cu alte cuvinte, detecția și explicația sunt două sarcini, nu una, iar ordinea contează: întâi decizi că există manipulare, apoi spui ce fel.

Ce rămâne de făcut

Pasul următor este construirea și testarea designului în doi pași pe aceleași 60 de perechi, pentru a măsura cât scade rata de alarme false când detecția precede explicația. Dincolo de asta, calibrarea și abținerea — un scor de încredere și opțiunea de a spune „nu sunt sigur” — rămân necesare înainte ca instrumentul să poată funcționa pe text real, dezordonat. Toate materialele acestei note — scriptul clasificatorului (13_technique_classifier.py), scriptul de metrici (14_technique_metrics.py) și predicțiile brute (technique_predictions.csv) — sunt în depozit.