Verificare țintită a negației: un semnal local promițător

Corectarea echivalenței fabricate când comparația este negată — rezultat pe o rulare, nu strategie validată

Șerban, G. F. · noiembrie 2026

Metoda și reconcilierea cifrelor

Verificatorul face două treceri: clasifică normal, apoi pune o întrebare focalizată NUMAI pe propozițiile etichetate „echivalență fabricată” — comparația este negată („unlike”, „but not”, „differently from”)? — și, dacă da, corectează la „niciuna”. O precizare metodologică necesară: scriptul rulat a RE-CLASIFICAT în prima trecere, cu un prompt mai scurt, producând 9 alarme false pe echivalență, diferit de cele 6 ale clasificatorului v2. Pentru a atribui curat efectul verificatorului, comparația de mai jos ține predicțiile v2 FIXE și aplică doar verificarea de negație peste ele; nu re-clasifică.

Rezultatul atribuibil (predicții v2 fixe)

Indicator	înainte	după verificare
Alarme false echivalență (controale)	6/60	0/60
Echivalențe adevărate prinse (pozitive)	10/10	9/10
Predicții schimbate în afara echivalenței	—	0

Ce se poate afirma — și ce nu

Formularea corectă: pe această rulare a setului de regresie, verificatorul țintit a redus alarmele false pentru echivalență de la 6 la 0, cu pierderea unei clasificări pozitive corecte (de la 10 la 9, cazul Q07), iar predicțiile celorlalte clase au rămas neschimbate. Este un compromis favorabil pentru obiectivul defensiv — a eticheta drept „face o comparație cu dictatura” pe cineva care spune explicit „nu ca o dictatură” era citirea periculoasă, iar ea a dispărut.

Trei restricții oneste. Întâi, „zero alarme false” pe aceste controale nu garantează același rezultat pe texte noi. În al doilea rând, Q07 este un efect advers al filtrului însuși (a citit greșit o comparație afirmată ca negată), deci „fără daune colaterale” se restrânge la CELELALTE clase, nu la echivalență. În al treilea rând, rezultatul susține verificarea negației în această configurație; nu demonstrează încă eficiența întregii strategii de verificări.

Falsa dilemă: ținta nu este numărul „doi”

Următoarea sită nu trebuie să numere opțiunile. Trei opțiuni pot forma tot o alegere fals închisă, iar două pot fi perfect legitime:

> *Două legitime: „Poți depune cererea online sau la ghișeu; ambele variante sunt disponibile.”*
>
> *Trei, fals exhaustive: „Ori susții proiectul, ori ești incompetent, ori urmărești interese ascunse.”*

Întrebarea verificatorului trebuie să vizeze mecanismul logic: „Textul prezintă alternativele ca fiind singurele posibile și exclude nejustificat alte posibilități relevante?” Cu trei rezultate — alternative explicit deschise: respinge eticheta; închidere nejustificată susținută de text: păstreaz-o; nedeterminabil: abținere. Numărul opțiunilor e un indiciu descriptiv, nu regula de decizie.

Următorul experiment

În ordine: (1) această versiune este documentată și salvată; (2) Q07 se repară restrângând întrebarea la negația relației de echivalare, nu la prezența oricărei negații; (3) se construiește verificatorul pentru exhaustivitatea nejustificată a alternativelor; (4) se testează inclusiv pe alegeri legitime cu două opțiuni și pe alegeri fals închise cu trei; (5) se validează pe un set neatins după ajustări. Și o corecție de metodă pentru viitor: verificatorul trebuie să încarce predicții salvate, nu să re-ruleze clasificatorul, ca efectul să fie atribuibil.

Materiale

Scriptul (17_negation_check.py), predicțiile v2 (contrastive_pairs_v3_v2_predictions.csv) și rularea verificatorului (contrastive_pairs_v3_negcheck.csv) sunt în depozit. Comparația atribuibilă de mai sus se reproduce aliniind cele două fișiere pe aceleași rânduri.