Verificare țintită a negației: 9 → 0 alarme false

O a doua trecere care corectează echivalența fabricată când comparația e negată

Șerban, G. F. · noiembrie 2026

Problema

Analiza de erori a clasificatorului v2 a arătat că alarmele false rămase pe echivalența fabricată sunt toate comparații explicit negate — „unlike the way dictatorships…", „but not the way a thief…". Modelul numea procedeul în ciuda negației. O instrucțiune generală nu a reparat asta. Soluția testată aici nu este încă o ajustare globală, ci o verificare țintită.

Metoda

Două treceri. Prima clasifică fiecare propoziție ca în v2. A doua se aplică NUMAI propozițiilor etichetate „echivalență fabricată" și pune o singură întrebare focalizată: comparația este negată sau respinsă („unlike", „not like", „but not", „differently from")? Dacă da, autorul nu execută echivalența, iar eticheta se corectează la „niciuna". Fiindcă a doua trecere atinge doar ce e deja marcat ca echivalență, nu poate schimba nicio altă tehnică.

Rezultatul

Indicator	înainte (v2)	după verificare
Alarme false echivalență (controale)	9/60	0/60
Echivalențe adevărate prinse (pozitive)	10/10	9/10
Alarme false totale, orice procedeu (controale)	26/60	17/60

Succes pe ținta cea mai periculoasă. Toate cele nouă comparații negate etichetate greșit au fost curățate (9 → 0). A eticheta drept „face o comparație cu dictatura" pe cineva care spune explicit „nu ca o dictatură" era tocmai citirea greșită care transformă un detector într-o unealtă de învinovățire; ea a dispărut.

Cost: o singură detecție pierdută. Pozitivele au scăzut de la 10 la 9. Cazul este Q07, o comparație afirmată („ia banii așa cum îi ia un hoț") pe care sub-întrebarea de negație a citit-o greșit ca negată și a corectat-o din greșeală la „niciuna". Este o singură eroare a verificatorului, remediabilă printr-o formulare mai strânsă a întrebării. Pentru un instrument defensiv, schimbul — nouă acuzații false eliminate contra unei detecții ratate — este favorabil.

Ce NU a reparat: cele opt alarme false pe falsă dilemă au rămas (toată scăderea totală, 26 → 17, vine din echivalențe). Era de așteptat — acela este un mecanism diferit, propozițiile cu trei opțiuni, care are nevoie de verificarea lui proprie („câte opțiuni sunt enumerate?”).

Lecția

Strategia verificărilor țintite funcționează. Mecanismul cel mai periculos a fost reparat curat, fără daune colaterale și fără o ajustare globală care să strice altceva. Drumul înainte nu este un model mai deștept peste tot, ci o sită de verificări mici, fiecare pe câte un procedeu, aplicate doar acolo unde procedeul a fost marcat. Următoarea sită firească este pentru falsa dilemă.

Materiale

Scriptul (17_negation_check.py) și predicțiile înainte/după (contrastive_pairs_v3_negcheck.csv) sunt în depozit, alături de clasificatorul v2 și de nota de analiză a erorilor.