De la etichetare retorică la verificare țintită

Alarme false, abținere și verificarea negației într-un clasificator bazat pe un model lingvistic

Șerban Gabriel Florin

Cercetător independent, Hannover, Germania

ORCID: 0009-0000-2266-3356

Repository: github.com/politomorphism/politomorphism-defense

Versiunea înghețată: explanation-v2-frozen

Statut: Preprint — raport preliminar, nerecenzat

Rezumat

Identificarea automată a procedeelor retorice poate sprijini lectura critică, dar poate produce și atribuiri nejustificate atunci când un sistem confundă vocabularul încărcat cu utilizarea efectivă a unui procedeu. Acest raport examinează un clasificator pentru șase categorii retorice, evaluat pe 60 de perechi contrastive, însumând 120 de texte. Clasificatorul inițial a identificat corect tehnica în 55 dintre cele 60 de exemple pozitive, dar a produs 39 de alarme false pe cele 60 de controale. O versiune cu instrucțiuni privind negația și citarea, precum și cu posibilitatea abținerii, a redus alarmele false la 16, cu scăderea clasificărilor pozitive corecte la 51. Aplicarea ulterioară a unui verificator țintit al negației, pe predicțiile salvate ale acestei versiuni, a eliminat cele șase alarme false de echivalență fabricată, cu pierderea unei clasificări pozitive corecte. Rezultatele descriu un compromis promițător între reducerea alarmelor false și păstrarea detecției. Ele provin însă dintr-un set utilizat în dezvoltare și nu constituie încă dovezi de generalizare pe date noi.

Cuvinte-cheie: modele lingvistice, procedee retorice, alarme false, abținere, negație, evaluare contrastivă.

1. Problema: identificarea unui procedeu nu este identificarea manipulării

Un sistem de analiză retorică trebuie să distingă între prezența unei structuri lingvistice și utilizarea ei problematică în context. O presupoziție poate fi justificată de informații comune

interlocutorilor. O întrebare retorică poate avea rol explicativ. O comparație nu este, prin simpla sa existență, înșelătoare.

Prin urmare, obiectivul evaluat aici este limitat: identificarea procedeului retoric folosit și asumat de autor, conform definițiilor operaționale ale setului, nu stabilirea intenției de manipulare.

Această delimitare este importantă pentru instrumentele defensive. O etichetă incorectă poate transforma o unealtă de lectură critică într-o sursă de acuzații nejustificate.

2. Setul de date și configurațiile analizate

Setul de dezvoltare conține 60 de perechi contrastive. Fiecare pereche include un exemplu pozitiv și un control etichetat ca lipsit de procedeul vizat. Cele șase categorii, fiecare reprezentată prin zece exemple pozitive, sunt: presupoziție; echivalență fabricată; falsă dilemă; whataboutism; întrebare retorică încărcată; cauzalitate implicită.

Au fost analizate trei configurații: (1) clasificatorul inițial, folosit ca referință; (2) clasificatorul v2, cu instrucțiuni explicite privind negația și citarea și cu posibilitatea de a răspunde „dovezi insuficiente”; (3) v2 cu verificarea negației, aplicată exclusiv predicțiilor inițiale de echivalență fabricată. Pentru comparația atribuibilă verificatorului, predicțiile v2 au fost păstrate fixe; clasificatorul de bază nu a fost rerulat cu un prompt diferit.

Configurația înghețată pentru testarea ulterioară utilizează gpt-4o-mini, temperatură 0, și este identificată în repository prin tagul explanation-v2-frozen. Temperatura 0 nu reprezintă, singură, o garanție de reproducibilitate perfectă.

3. Indicatorii de evaluare

Evaluarea separă: alarmă falsă (atribuirea unei tehnici unui control); respingere corectă (răspunsul „niciuna” pentru un control); abținere (răspunsul „dovezi insuficiente”); detecție pozitivă (atribuirea oricărei tehnici unui exemplu pozitiv); clasificare corectă (atribuirea tehnicii din eticheta de referință). Abținerea nu este considerată clasificare corectă. De asemenea, detectarea unei tehnici greșite nu este echivalentă cu identificarea corectă a procedeului.

4. Rezultatele clasificatorului v2

Indicator	Clasificator inițial	V2
Alarme false pe controale	39/60 — 65%	16/60 — 26,7%
Controale clasificate corect	21/60 — 35%	25/60 — 41,7%
Abțineri pe controale	0/60	19/60 — 31,7%
Pozitive cu tehnica numită corect	55/60 — 91,7%	51/60 — 85%

Recall-ul detecției	57/60 — 95%	52/60 — 86,7%

V2 reduce rata alarmelor false cu 38,3 puncte procentuale, dar această reducere este însoțită de mai multe abțineri și de scăderea detecției pe pozitive. Numărul total de clasificări exact corecte rămâne același: 76 din 120 în ambele configurații. Avantajul v2 constă, așadar, în schimbarea distribuției rezultatelor, nu într-o creștere a corectitudinii exacte totale. Pentru o utilizare defensivă, înlocuirea unei acuzații greșite cu o abținere poate avea valoare practică.

Performanța diferă puternic între categorii. Presupoziția scade de la șapte la două clasificări corecte din zece. În schimb, falsa dilemă, whataboutismul și întrebarea retorică încărcată păstrează câte zece clasificări pozitive corecte. Pe controale, falsa dilemă și echivalența fabricată însumează 14 dintre cele 16 alarme false. Pentru întrebarea retorică încărcată, toate cele zece controale produc abțineri, nu respingeri corecte.

5. Verificarea țintită a negației

Verificatorul suplimentar examinează dacă relația de echivalare identificată de clasificator este afirmată sau negată. Pe baza v2 păstrată fixă, rezultatul raportat este: alarme false de echivalență pe controale 6 → 0; echivalențe pozitive clasificate corect 10 → 9; predicțiile din afara clasei inițial vizate, neschimbate. Eroarea introdusă apare la exemplul Q07: verificatorul tratează o comparație afirmată ca fiind negată și înlocuiește eticheta corectă cu „niciuna”.

Rezultatul susține utilitatea locală a unei verificări semantice țintite. Nu demonstrează însă că verificatorul înțelege negația în toate construcțiile sau că efectul se va păstra pe texte noi. O problemă de trasabilitate a fost, de asemenea, clarificată: o rulare cu un prompt de bază mai scurt produsese alte totaluri; acea rulare nu este utilizată pentru estimarea efectului verificatorului asupra v2.

6. Limite și validare planificată

Limita principală este utilizarea repetată a acelorași 60 de perechi pentru analiza erorilor și ajustarea sistemului. Rezultatele sunt descriptive pentru acest set, dar pot supraestima performanța în afara lui. Alte limite: numărul mic de exemple pe categorie, dependența de definițiile etichetelor și lipsa unei evaluări independente finalizate.

Următorul experiment prevede un set nou de 60 de perechi, cu teme și construcții diferite, etichete stabilite înainte de rulare și texte prezentate individual. V2 va fi rulat fără modificări, iar verificatorul va fi aplicat predicțiilor salvate. Criteriile exploratorii de acceptare pentru v2 sunt: cel mult 22 de alarme false din 60 de controale; cel puțin 48 de exemple detectate din 60 de pozitive. Pentru verificator se urmăresc reducerea relativă cu minimum 75% a alarmelor false pe comparațiile negate și pierderea a cel mult unei clasificări corecte din zece echivalențe pozitive;

efectul reducerii nu poate fi evaluat dacă baza nu produce asemenea alarme false. Aceste praguri sunt criterii pragmatice de pilot, nu standarde universale și nici teste suficiente pentru demonstrarea generalizării.

7. Concluzie

Experimentul arată că identificarea corectă a procedeelor pe exemple pozitive poate coexista cu o rată ridicată a alarmelor false. Introducerea abținerii și a instrucțiunilor contextuale reduce aceste alarme, dar poate ascunde pierderi importante pe anumite categorii. Verificarea țintită a negației oferă un rezultat local favorabil: eliminarea a șase etichetări false, cu pierderea unei clasificări pozitive corecte. Concluzia justificată este că această abordare merită testată pe date noi, nu că problema a fost rezolvată. Pentru un instrument defensiv, performanța trebuie evaluată prin echilibrul dintre detecție, erori de atribuire și capacitatea de a recunoaște incertitudinea.

Disponibilitatea materialelor

Codul, definițiile etichetelor, predicțiile și protocolul de validare sunt publice la github.com/politomorphism/politomorphism-defense. Versiunea înghețată: explanation-v2-frozen.

Addendum: Evaluare held-out efectuata

Configuratia inghetata (explanation-v2-frozen, gpt-4o-mini, temperatura 0) a fost rulata nemodificat pe un set held-out de 60 de perechi noi (contrastive_pairs_v4_heldout.csv), cu teme si constructii diferite, etichetat inainte de rulare. Pragurile de acceptare fusesera inregistrate in protocol inainte de evaluare, inclusiv pentru verificatorul de negatie.

Indicator	Valoare	Prag	Rezultat
Alarme false (v2)	16/60	<= 22/60	INDEPLINIT
Recall detectie (v2)	54/60	>= 48/60	INDEPLINIT
Reducere echivalenta (comparatii negate)	7 -> 0 (100%)	>= 75%	INDEPLINIT
Echivalente pozitive pierdute	0 din 10	<= 1	INDEPLINIT
Schimbari in afara echivalentei	0	0	INDEPLINIT
Alarme false totale dupa verificator	16/60 -> 9/60	-	-

Cele 9 alarme false ramase: sase la falsa dilema (controale cu trei optiuni), doua la whataboutism etichetate ca cauzalitate implicita, una la cauzalitate implicita. Cele 7 corectii ale verificatorului au devenit respingeri corecte ('niciuna'), nu abtineri.

Verdict: Configuratia inghetata a indeplinit toate criteriile prestabilite de acceptare pe un set held-out construit de autor. Dupa aplicarea verificatorului de negatie, alarmele false totale au scazut de la 16/60 la 9/60, iar recall-ul a ramas 54/60. Rezultatul nu constituie validare independenta si nu demonstreaza generalizarea; este un rezultat favorabil pe acest set, nu o excludere a variatiei intamplatoare.

Validare independenta planificata

Pasul ramas este evaluarea cu adnotatori umani independenti, care nu au ajustat sistemul, cu etichete stabilite inainte si dezacorduri rezolvate. Un set construit de autor ofera o evaluare separata de datele de dezvoltare, dar nu constituie validare independenta.