Protocol de validare pe date noi — stratul de explicație

Îngheț, set ținut separat, criterii pre-stabilite · Șerban, G. F. · noiembrie 2026

1. Configurația înghețată

Reper înghețat în Git: eticheta explanation-v2-frozen (commit 0788a33). Model: gpt-4o-mini, temperatură 0. Set: contrastive_pairs_v3.csv (60 de perechi, v0.3), definiții de etichetă pe două axe (gold_structure, gold_use). Artefacte salvate în depozit: 16_classifier_v2_abstention.py, 17_negation_check.py, predicțiile fiecărei rulări, hard_controls.csv. Până la încheierea validării nu se mai repară Q07 și nu se mai adaugă verificatorul pentru falsa dilemă.

Reconcilierea cifrelor (rezolvată): baza v2 autoritară este rularea scriptului 16 (prompt complet) — 16/60 alarme false pe controale, din care 6 pe echivalență. Cele 26 (din care 9 pe echivalență) proveneau din scriptul 17, care RE-CLASIFICĂ în prima trecere cu un prompt mai scurt; nu sunt aceeași bază și nu se compară. Comparația atribuibilă a verificatorului de negație ține predicțiile scriptului 16 FIXE: echivalență 6→0, pozitive 10→9, nimic schimbat în afara echivalenței.

2. Setul nou, ținut separat (pilot)

60 de perechi noi (120 de texte), zece pe fiecare tehnică — pilot util, nu suficient pentru concluzii ferme pe fiecare clasă. Cerințe: alte situații, teme și construcții, nu sinonime ale celor vechi; controale cu vocabular încărcat, negație și citare; procedee legitime, inclusiv presupoziții confirmate; alegeri cu două opțiuni legitime și cu trei opțiuni fals prezentate ca exhaustive; exemple pozitive fără vocabular alarmant. Etichetele se stabilesc ÎNAINTE de rulare, pe cele două axe, de preferință de o persoană care nu ajustează prompturile; ideal doi evaluatori care rezolvă dezacordurile. Cazurile fără etichetă structurală clară se păstrează separat pentru analiza ambiguității. Nota de contaminare: setul ar trebui construit/verificat de cineva din afara ajustării prompturilor; dacă nu e posibil acum, se marchează explicit ca „construit de autor, necesită verificare independentă”.

3. Rularea configurațiilor, fără modificări

Pe fiecare text individual, fără a arăta modelului perechea sau eticheta: (1) v2 (scriptul 16, neschimbat); (2) aceleași predicții v2 trecute prin verificatorul de negație — care încarcă predicțiile salvate, NU re-rulează clasificatorul de bază, ca efectul verificatorului să fie atribuibil. (v1 doar dacă se reface configurația originală.)

4. Criteriul de succes — se fixează ACUM, înainte de test

Nu „scad alarmele false”. Propunere de prag, de confirmat de tine înainte de orice rulare (limita depinde de utilizare și nu se alege după rezultate):

(a) Generalizarea v2: pe setul nou, rata de alarme false pe controalele fără procedeu nu mai rea cu mai mult de 10 puncte decât pe cele 60 (adică ≤ ~37%), iar recall-ul detecției pe pozitive nu mai mic cu mai mult de 8 puncte (adică ≥ ~79%). (b) Beneficiul verificatorului de negație: pe controalele cu comparație negată, alarmele false pentru echivalență scad cu cel puțin trei sferturi, cu o pierdere de recall pe echivalență de cel mult o detecție la zece, și fără ca recall-ul vreunei alte tehnici să scadă cu peste 15 puncte. Dacă oricare condiție cade, verificatorul NU se declară generalizat.

Raportare obligatorie, cu numere absolute și pe clase: alarme false; controale corect respinse („niciuna”); abțineri; recall-ul detecției; tehnica numită corect; totul defalcat pe cele șase tehnici.

5. Decizia de după

Dacă beneficiul se păstrează: primele dovezi de generalizare pe un set separat — abia atunci se repară Q07 și se construiește verificatorul pentru falsa dilemă (vizând mecanismul logic — „alternativele sunt prezentate ca singurele posibile și se exclud nejustificat altele?” — nu numărul de opțiuni). Dacă dispare: analiză de erori și revizuire a sistemului. Odată ce erorile setului nou sunt folosite pentru ajustare, el devine set de dezvoltare/regresie, iar următoarea validare cere alte date.

Despre publicare, în paralel

Lucrarea III poate fi distribuită ca preprint dacă afirmațiile sunt delimitate și limitările explicite — dar un DOI sau încărcarea pe o platformă nu înseamnă validare științifică ori recenzare. Publicarea merge în paralel, nu înlocuiește testarea. Confirmarea că Lucrarea III e gata de distribuit cere citirea conținutului și a afirmațiilor ei, separat.