Protocol de validare pe date noi — criterii blocate

Stratul de explicație · configurație înghețată · Șerban, G. F. · noiembrie 2026

1. Configurația înghețată

Reper în Git: tagul explanation-v2-frozen. Model: gpt-4o-mini, temperatură 0 (nu garantează singură reproducibilitate perfectă). Set de dezvoltare: contrastive_pairs_v3.csv. Artefacte salvate: scripturile 16 (v2), 17 și 18 (verificare pe predicții salvate), predicțiile fiecărei rulări, definițiile de etichetă pe două axe. Până la încheierea validării nu se repară Q07 și nu se adaugă verificatorul pentru falsa dilemă.

Reconciliere: baza v2 autoritară = scriptul 16 (prompt complet), 16/60 alarme false, din care 6 echivalență. Cele 26 (9 echivalență) veneau din scriptul 17 care re-clasifica cu prompt mai scurt — necomparabile; nu se folosesc la estimarea efectului verificatorului.

2. Setul nou, ținut separat

Construit: contrastive_pairs_v4_heldout.csv — 60 de perechi noi (120 de texte), zece pe tehnică, teme și construcții diferite de cele vechi; controalele de echivalență sunt comparații negate; o parte din pozitive folosesc vocabular blând. Bloc special: hard_controls_v4.csv — presupoziție confirmată (legitimă), două opțiuni legitime, trei opțiuni fals exhaustive, comparație negată, citare contestată, cauzalitate prudentă. Etichetele sunt stabilite pe două axe (gold_structure, gold_use) ÎNAINTE de orice rulare. Avertisment de contaminare: setul este construit de autor și necesită verificare independentă; nu constituie validare independentă.

3. Rularea configurației înghețate, fără modificări

Pe fiecare text individual, fără pereche și fără etichetă arătate modelului: (1) v2 cu scriptul 16 neschimbat, pe contrastive_pairs_v4_heldout.csv; (2) scriptul 18 aplică verificarea negației pe predicțiile SALVATE ale lui v2 — nu re-clasifică — atingând numai rândurile etichetate manufactured_equivalence.

4. Criterii de acceptare — BLOCATE înainte de test

Acestea sunt criterii pragmatice de pilot, nu standarde universale și nici dovadă de generalizare.

Criteriu (v2, 60 controale / 60 pozitive)	Prag blocat
Rata alarmelor false	cel mult 22/60
Recall-ul detecției	cel puțin 48/60

Ambele condiții trebuie îndeplinite. Abținerile NU sunt controale clasificate corect și rămân în numitorul recall-ului. Se raportează numere absolute și intervale de încredere pentru rate, plus

clasificarea corectă a tehnicii și rezultatele pe clase (pragurile globale pot ascunde, de pildă, problema presupoziției). Concluzia corectă: „V2 îndeplinește criteriile prestabilite de acceptare pe acest set nou” — NU „am demonstrat că v2 generalizează”.

Verificatorul de negație (condiții blocate):

(a) Reducere relativă de minimum 75% a etichetelor false de echivalență pe subsetul de comparații negate, definit înainte de rulare, cu reducere = (FP_înainte − FP_după)/FP_înainte. Dacă baza are zero asemenea erori, efectul este NEEVALUABIL, nu succes; dacă are foarte puține, se raportează numerele brute și fragilitatea procentului, fără a adăuga exemple după rezultate. (b) Pierdere de cel mult o clasificare corectă din zece echivalențe pozitive, numărând pierderile individuale, nu diferența netă. (c) Condiție de implementare verificabilă: nicio predicție inițială diferită de manufactured_equivalence nu poate fi modificată; în plus, zero pierderi de detecție produse de filtru pe pozitivele celorlalte clase (un exemplu etichetat greșit drept echivalență și apoi transformat în „niciuna”). Scriptul 18 garantează prin construcție condiția (c).

5. Decizia de după

Dacă criteriile sunt îndeplinite: prima evaluare separată de datele de dezvoltare — abia apoi se repară Q07 (restrângând întrebarea la negația relației de echivalare) și se construiește verificatorul pentru falsa dilemă, vizând mecanismul logic („alternativele sunt prezentate ca singurele posibile și se exclud nejustificat altele?”), nu numărul de opțiuni. Dacă nu sunt îndeplinite: analiză de erori și revizuire. Odată ce erorile setului nou sunt folosite pentru ajustare, el devine set de dezvoltare/regresie, iar următoarea validare cere alte date.

Publicarea merge în paralel, dar nu înlocuiește testarea: un DOI sau încărcarea pe o platformă nu înseamnă validare științifică ori recenzare.