Studiul 2 — testul mecanismului / Study 2 — mechanism test

Familii de exemple care diferă printr-o singură proprietate · Șerban, G. F. · noiembrie 2026

Română

Scop

Studiul 2 verifică dacă îmbunătățirea detectorului provine din tratarea structurii relevante, nu din memorarea unor indicii de suprafață. Pentru asta, cinci familii de exemple diferă printr-o singură proprietate; eticheta corectă se schimbă doar în funcție de acea proprietate. Setul (study2_mechanism_families.csv) are 30 de exemple, câte şase pe familie (trei pe fiecare pol).

Cele cinci familii

1. Afirmare vs negare: aceeaşi comparație, afirmată (procedeu prezent) sau negată (absent). 2. Citare vs asumare: o echivalare asumată de autor (prezent) vs atribuită altora şi contestată (absent). 3. Comparație justificată vs nejustificată: o comparație factuală, exactă (absent) vs o echivalare între lucruri diferite (prezent). 4. Presupoziție păstrată vs anulată: premisa codificată ca dată (prezent) vs pusă ca întrebare (absent). 5. Sfera negației — familia decisivă: negație relevantă, care anulează echivalarea (absent), vs negație în altă propoziție, care lasă procedeul intact (prezent).

De ce contează familia 5

Exemplele E2, E3, E5 conțin cuvinte de negație ('nicio greşeală', 'nu e o exagerare', 'nu voi nega'), dar negația nu atinge echivalarea — aceasta este afirmată. Un model care se bazează pe simpla prezență a lui 'nu' le va clasifica greşit drept absent. La fel, verificatorul de negație trebuie testat aici: dacă Şterge echivalarea în E2/E3/E5, înseamnă că reacționează la token-ul 'nu', nu la sfera lui. Aceasta este proba care distinge înțelegerea structurii de memorarea unui indiciu.

Cum se rulează (fără oameni)

Se compară, pe aceeaşi familie: clasificatorul v2 (scriptul 16), apoi verificatorul de negație pe predicțiile salvate (scriptul 18). Se raportează, pe familie: acuratețea pe axa structurii (procedeu prezent / absent), şi, pentru familia 5, dacă modelul şi verificatorul respectă sfera negației. Familiile trebuie ținute separat între dezvoltare şi test, pentru a evita ca variații aproape identice să ajungă în ambele. Rezultatul urmărit: să arăți că îmbunătățirea vine din structură, nu din indicii.

English

Purpose

Study 2 tests whether the detector's improvement comes from handling the relevant structure rather than memorizing surface cues. Five families of examples differ by a single property; the correct label changes only with that property. The set (study2_mechanism_families.csv) has 30 examples, six per family (three per pole).

The five families

1. Affirmation vs negation: the same comparison, asserted (device present) or negated (absent). 2. Quotation vs assertion: an equivalence endorsed by the author (present) vs attributed to others and disputed (absent). 3. Justified vs unjustified comparison: an accurate, factual comparison (absent) vs equating unlike things (present). 4. Presupposition kept vs cancelled: a premise encoded as given (present) vs put as a question (absent). 5. Negation scope — the decisive family: a relevant negation that cancels the equivalence (absent) vs a negation in another clause that leaves the device intact (present).

Why family 5 matters

Examples E2, E3, E5 contain negation words ('make no mistake', 'not an exaggeration', 'will not deny'), but the negation does not touch the equivalence — which is asserted. A model relying on the mere presence of 'not' will misclassify them as absent. The negation verifier must be tested here too: if it clears the equivalence in E2/E3/E5, it is reacting to the token 'not', not to its scope. This is the probe that separates understanding structure from memorizing a cue.

How to run (no humans)

Compare, on the same families: the v2 classifier (script 16), then the negation verifier on the saved predictions (script 18). Report, per family: accuracy on the structure axis (device present/absent), and, for family 5, whether the model and the verifier respect negation scope. Keep families separate between development and test so that near-identical variants do not fall into both. Intended result: to show the improvement comes from structure, not from cues.