Evaluare bilingva (EN–RO) a clasificatorului de structura / Bilingual (EN–RO) evaluation

Set contrastiv paralel, 60 de perechi pe limba · configuratie explanation-v2-frozen · Șerban, G. F. · noiembrie 2026

ROMÂNĂ

1. Comparatia numerica (trei rezultate distincte pe controale)

Indicator	Română	Engleză	Dif. RO–EN
Alarme false pe controale	19/60 (31,7%)	16/60 (26,7%)	+5,0 pp
Respingeri corecte explicite ('niciuna')	19/60 (31,7%)	23/60 (38,3%)	−6,7 pp
Abțineri pe controale	22/60 (36,7%)	21/60 (35,0%)	+1,7 pp
Recall detecție	52/60 (86,7%)	54/60 (90,0%)	−3,3 pp
Tehnică identificată corect	49/60 (81,7%)	52/60 (86,7%)	−5,0 pp

Româna este uşor mai slabă pe indicatorii raportați, dar diferențele absolute sunt mici (2–4 exemple). Cu numai 60 de perechi, aceste totaluri nu stabilesc echivalența performanțelor. Abținerea nu este o respingere corectă explicită: cele trei rezultate pe controale se păstrează separate, iar rata alarmelor false nu descrie singură calitatea clasificatorului.

2. Analiza pereche cu pereche (EN vs RO)

Pe cele 120 de exemple, EN şi RO dau aceeaşi etichetă în 85% din cazuri (102/120): 90% pe pozitive, 80% pe controale. Apropierea agregată ascunde aşadar dezacorduri la nivel de exemplu. Pe comparatiile negate, fiecare limbă produce şapte alarme false, dar nu pe aceleasi şapte exemple: şase coincid (M01–M04, M07, M08), engleza greşeşte unic pe M09, româna pe M10. La presupoziție, engleza ratează şase pozitive, româna opt, din care cinci comune. Dificultățile se păstrează în mare parte între limbi, dar nu identic.

3. Ce se poate afirma — şi ce nu

Susținut: performanțele agregate EN–RO sunt apropiate pe acest set paralel; presupoziția rămâne un punct slab în română; negația şi controalele cu trei opțiuni produc multe alarme false în ambele limbi. Prea puternic deocamdată: afirmația că „comportamentul de detecție nu depinde de limbă” — s-au testat două limbi, un set tradus şi o anumită configurație; apropierea nu demonstrează independența față de limbă, nici mecanismul care o produce. Afirmația „prima evaluare contrastivă sistematică engleză–română” necesită verificare bibliografică şi nu este făcută aici.

4. Formularea păstrată în raport

Pe un set contrastiv paralel construit de autor, format din 60 de perechi în fiecare limbă, clasificatorul a obținut rezultate agregate apropiate în engleză şi română. Recall-ul detecției a fost de 90,0% în engleză şi 86,7% în română, iar rata alarmelor false pe controale a fost de 26,7%, respectiv 31,7%. Rezultatele sunt compatibile cu un transfer interlingvistic preliminar, dar nu stabilesc echivalența performanței sau generalizarea la discursul românesc autentic.

5. Pasul următor

Versiunea actuală este înghețată (set, prompt, model, setări, predicții individuale în repository). Urmează adaptarea verificatorului de negație în română şi testarea sa, fără a presupune că duce erorile la zero: se verifică dacă reduce alarmele false pe comparații negate, dacă nu elimină detecții valide şi dacă funcționează şi pe exemple noi, nu doar pe cele şapte erori cunoscute.

ENGLISH

1. Numerical comparison (three distinct control outcomes)

Indicator	Romanian	English	Diff RO–EN
False alarms on controls	19/60 (31.7%)	16/60 (26.7%)	+5.0 pp
Explicit correct rejections ('none')	19/60 (31.7%)	23/60 (38.3%)	−6.7 pp
Abstentions on controls	22/60 (36.7%)	21/60 (35.0%)	+1.7 pp
Detection recall	52/60 (86.7%)	54/60 (90.0%)	−3.3 pp
Technique named correctly	49/60 (81.7%)	52/60 (86.7%)	−5.0 pp

Romanian is slightly weaker on the reported indicators, but the absolute differences are small (2–4 examples). With only 60 pairs, these totals do not establish performance equivalence. Abstention is not an explicit correct rejection: the three control outcomes are kept separate, and the false-alarm rate alone does not describe classifier quality.

2. Pair-by-pair analysis (EN vs RO)

Across the 120 examples, EN and RO give the same label in 85% of cases (102/120): 90% on positives, 80% on controls. Aggregate closeness thus hides item-level disagreement. On negated comparisons each language produces seven false alarms, but not on the same seven examples: six coincide (M01–M04, M07, M08), English uniquely errs on M09 and Romanian on M10. For presupposition, English misses six positives, Romanian eight, five of them shared. The difficulties largely persist across languages, but not identically.

3. What can and cannot be claimed

Supported: aggregate EN–RO performance is close on this parallel set; presupposition remains weak in Romanian; negation and three-option controls produce many false alarms in both languages. Too strong for now: the claim that detection behaviour is language-independent — two languages, a translated set, and one model configuration were tested; closeness does not demonstrate independence from language, nor the mechanism producing it. The claim of a first systematic EN–RO contrastive evaluation requires a bibliographic check and is not made here.

4. Wording retained for the report

On an author-built parallel contrastive set of 60 pairs per language, the classifier achieved close aggregate results in English and Romanian. Detection recall was 90.0% in English and 86.7% in Romanian, and the control false-alarm rate was 26.7% and 31.7% respectively. The results are compatible with preliminary cross-lingual transfer but do not establish performance equivalence or generalization to authentic Romanian discourse.

5. Next step

The current version is frozen (set, prompt, model, settings, individual predictions in the repository). Next is adapting the negation verifier to Romanian and testing it, without assuming it drives errors to zero: checking whether it reduces false alarms on negated comparisons, does not remove valid detections, and works on new examples, not only the seven known errors.