Extinderea instrumentului defensiv: română, text real, explicație

Notă de plan — Politomorphism, stratul de audit defensiv · noiembrie 2026

Șerban, G. F.

De ce aceste trei direcții, împreună

Lucrările I–III au stabilit, pe engleză, că un model contextual detectează structura manipulării, nu doar vocabularul ei, pe un set de perechi contrastive bine controlat. Trei limite rămân pentru ca instrumentul să treacă de la diagnostic de laborator la unealtă de audit reală: funcționează doar pe engleză, doar pe propoziții construite special, și doar scorează fără să spună ce tehnică a găsit. Cele trei direcții de mai jos ridică exact aceste trei limite și, tratate ca un singur program, se sprijină reciproc: fiecare pereche românească, scrisă în registru politic realist și etichetată pe tehnică, servește toate trei deodată.

Brațul 1 — Română

Aproape toată detecția de propagandă din literatură este pe engleză. Monitorizarea media românească este terenul propriu al programului (Politomorf Pipeline, SYMBOVOLT). Întrebarea „un model contextual detectează structura manipulării și în română?" este aproape neexplorată și distinge programul de restul domeniului. Primul pas este livrat odată cu această notă: un set-pilot de 18 perechi contrastive în română (trei pe fiecare dintre cele șase tehnici), cu actori generici — „consiliul", „ministrul", „guvernul" — fără nume reale, din motive etice. Potrivirea lexicală medie este 0.41, cu aceleași tehnici slabe ca la engleză (falsa dilemă, întrebarea retorică), care se vor strânge la iterația următoare, așa cum s-a întâmplat la setul englezesc (0.21 → 0.53).

Brațul 2 — Text real

Perechile construite izolează structura prin design, dar un sceptic poate spune că sunt artificiale. Pasul următor este să pornim de la fragmente reale de text politic românesc care conțin clar o tehnică, și să scriem controlul păstrând cât mai multe cuvinte, documentând ce s-a schimbat și de ce. Dacă decalajul structural se păstrează pe aceste perechi semi-naturale, instrumentul rezistă criticii „stimuli artificiali" și începe să funcționeze pe realitate — puntea către Narrative Atlas, unde textul este autentic și dezordonat.

Brațul 3 — Explicație pe tehnică

Scopul declarat al stratului defensiv este detectare, măsurare și explicație. Acum instrumentul doar scorează. Eticheta de tehnică pe fiecare pereche este primul pas spre explicație: nu „acest text este 0.8 manipulativ”, ci „aici este o falsă dilemă, aici o întrebare retorică încărcată”. Odată ce avem perechi etichetate pe tehnică în română, putem măsura acuratețea nu doar global, ci pe tehnică, și putem cere modelului să numească tehnica — ceea ce face dintr-o cutie neagră un instrument pe care un auditor uman îl poate folosi.

Problema de rezolvat: cum scorăm în română

Pentru engleză exista corpusul PropXplain, pe care s-au antrenat baseline-ul lexical și transformerul. Pentru română nu există un corpus de propagandă etichetat, deci pipeline-ul englezesc (antrenează pe corpus, scorează perechile) nu se transferă. Pentru pilot propun calea pragmatică: folosim ca model contextual un model care știe română din start — gpt-4o-mini, deja folosit ca evaluator independent, care gestionează bine româna — adaptând promptul în română, și raportăm acuratețea pe pereche și pe tehnică. Linia lexicală de comparație rămâne de decis: fie un model TF-IDF antrenat pe un eșantion de text politic românesc neetichetat folosit doar ca referință de vocabular, fie o listă de cuvinte-marcă. Este întrebarea deschisă a brațului 1, și o decidem înainte de rulare.

Secvența propusă

1) Validăm și strângem setul-pilot românesc (18 → 30 de perechi, potrivire ≥ 0.50). 2) Adaptăm scriptul de evaluare în română și îl rulăm cu gpt-4o-mini ca scorer contextual, raportând acuratețea pe tehnică. 3) Decidem și adăugăm o linie lexicală de comparație pentru română. 4) Construim un mic set semi-natural din text real. 5) Abia după ce acuratețea pe tehnică este stabilă, scriem aceasta ca o a patra lucrare — sau ca o extensie multilingvă a Lucrării III. Fiecare pas produce un artefact deschis în repository, ca și până acum.