Structură, nu vocabular: un instrument diagnostic cu perechi contrastive pentru detectarea manipulării politice

Lucrarea de lucru III în Antropologie Politică Computațională

Șerban Gabriel Florin

Cercetător independent, Hanovra, Germania

ORCID: 0009-0000-2266-3356

Cod și date: github.com/politomorphism/politomorphism-defense

Noiembrie 2026 — continuă Lucrările de lucru I și II

Citare: Șerban, G. F. (2026). Zenodo. https://doi.org/10.5281/zenodo.23884579

Rezumat

Detectoarele antrenate pe corpusuri de propagandă pot semnala un vocabular încărcat fără a reprezenta structura retorică ce face un text manipulativ. Lucrările de lucru I și II au comparat o linie de bază lexicală și un transformer ajustat fin pe o re-împărțire disjunctă pe articole a corpusului englezesc PropXplain, dar niciuna nu a putut separa sensibilitatea la structură de un corelat lexical. Această lucrare introduce un instrument diagnostic cu perechi contrastive pentru a face această separare. Fiecare item este o pereche de propoziții politice scurte pe aceeași temă, potrivite ca vocabular (suprapunere Jaccard medie între membri 0,50), în care un membru poartă exact un singur procedeu manipulativ — presupoziție, echivalență fabricată, falsă dilemă, whataboutism, întrebare retorică încărcată sau cauzalitate implicită — iar celălalt enunță același conținut în mod simplu. Fiindcă vorbele sunt ținute aproape constante, un model care acordă un scor mai mare membrului manipulativ trebuie să răspundă la structură. Pe șaizeci de astfel de perechi (zece pe fiecare tehnică), linia de bază lexicală (TF-IDF + regresie logistică) atinge o acuratețe pe pereche de 0,633 [IÎ 95% 0,51, 0,76], abia peste valoarea de hazard 0,50, în timp ce DistilBERT ajustat fin atinge 0,917 [0,85, 0,99]; intervalele de încredere nu se suprapun, iar un test pereche pe aceleași perechi confirmă diferența (McNemar exact p = 0,0002). Decalajul este concentrat acolo unde modelul lexical eșuează structural — falsa dilemă (0,30 la 1,00) și întrebările retorice încărcate (0,00 la 0,70). Pe cinci semințe de antrenament marginea transformerului este stabilă (acuratețe medie pe pereche 0,880, IÎ 95% [0,852, 0,908]; fiecare sământă peste linia de bază). Un evaluator independent (OpenAI gpt-4o-mini), orb față de construcție, etichetează cei 120 de membri cu acord substanțial față de etichetele autorului (kappa Cohen 0,617; pe perechi 0,917), iar erorile lui cad pe alte tehnici decât cele ale detectoarelor, ceea ce argumentează că perechile sondează structuri distincte, nu un singur artefact de vocabular. O analiză a reziduului lexical confirmă că marginea este structurală: avantajul transformerului nu corelează cu suprapunerea lexicală a perechilor (r = +0,04, nesemnificativ), în timp ce succesul liniei de bază lexicale corelează semnificativ cu ea (r = +0,50, p < 0,001). Instrumentul este oferit ca diagnostic cu materiale complet deschise, nu ca o măsură validată a manipulării; limitele rămase — un evaluator model, nu uman, o diferență reziduală de vocabular și stimuli construiți de autor — definesc pașii următori.

Cuvinte-cheie: validitate de construct; evaluare contrastivă; detectarea propagandei; structură retorică; manipulare; DistilBERT; acord între evaluatori; antropologie politică computațională; Politomorfism

1. Întrebarea: structură sau vocabular?

Un text este manipulativ politic nu din cauza cuvintelor pe care le folosește, ci din cauza a ceea ce face cu ele — presupunând o afirmație contestată ca fiind stabilită, forțând o falsă alegere ori/ori, deviind o critică arătând spre cealaltă tabără. Același vocabular încărcat poate apărea într-o propoziție simplă și onestă, iar o structură manipulativă poate fi construită din cuvinte blânde. Orice detector menit să sprijine un audit defensiv al comunicării politice trebuie, prin urmare, să răspundă la o întrebare prealabilă despre sine însuși: atunci când semnalează un pasaj drept propagandă, răspunde la structura retorică sau doar la un vocabular care corelează cu propaganda în corpusul său de antrenament? Cele două sunt ușor de confundat, fiindcă în corpusurile naturale cuvintele încărcate și structurile manipulative circulă împreună. Un detector poate obține un scor bun pe o partiție reținută a aceluiași corpus deși a învățat doar corelatul lexical, iar această distincție este invizibilă pentru orice evaluare făcută pe corpusul însuși.

Aceasta este o întrebare de validitate de construct în sensul clasic: instrumentul măsoară constructul pe care pretinde că îl măsoară sau un factor confundător (Cronbach & Meehl, 1955)? Cele două lucrări care o preced nu au putut-o soluționa. Lucrarea de lucru I a construit o linie de bază lexicală transparentă pe o re-împărțire disjunctă pe articole a corpusului englezesc PropXplain; Lucrarea de lucru II a arătat că un transformer ajustat fin clasifică aceleași etichete mai bine la cost egal de revizuire. Ambele rezultate sunt despre transferul etichetelor de corpus — prezicerea etichetelor de propagandă ale corpusului — și ambele tac asupra întrebării dacă vreunul dintre modele reprezintă manipularea ca structură. Această lucrare construiește un instrument proiectat anume pentru a le separa și raportează ce constată.

2. Metodă: perechi contrastive

Metoda este de a ține vocabularul aproape fix și de a varia doar structura. Fiecare item este o pereche de propoziții scurte pe aceeași temă. Un membru, membrul manipulativ, introduce exact un singur procedeu retoric numit; celălalt, controlul, enunță același conținut în mod simplu — ca o întrebare deschisă, o afirmație atribuită sau o enunțare cu mai multe opțiuni — eliminând procedeul fără a adăuga altul. Cei doi membri sunt scriși astfel încât să împartă cât mai multe cuvinte de conținut, pentru ca diferența dintre ei să fie structurală, nu lexicală. Un model care atribuie un scor de propagandă mai mare membrului manipulativ al unei perechi bine potrivite trebuie să răspundă la ceva dincolo de lista de cuvinte.

O pereche validă respectă cinci reguli de construcție: aceeași temă; vocabular potrivit; exact un procedeu structural în membrul manipulativ; un control simplu care elimină procedeul fără a introduce unul nou; și o motivație scrisă de o propoziție, care consemnează de ce fiecare membru este ceea ce este. Sunt acoperite șase procedee, fiecare preluat din taxonomia standard a tehnicilor de propagandă și manipulare (Da San Martino et al., 2020) și din pragmatică: presupoziția (o propoziție contestată codificată ca dată), echivalența fabricată (două lucruri diferite afirmate ca identice), falsa dilemă (o alegere redusă la două opțiuni), whataboutismul (o critică deviată spre adversar), întrebarea retorică încărcată (o întrebare care își afirmă propriul răspuns) și cauzalitatea implicită (cauzalitate dedusă din simpla succesiune sau coincidență). Ancorarea definițiilor procedeelor în taxonomia publicată, în locul judecății private, este deliberată: face din fiecare etichetă aplicarea unei definiții publice pe care alții o pot contesta.

Metrica principală este acuratețea pe pereche: fracția perechilor în care membrul manipulativ primește scorul de propagandă mai mare. Pe perechi perfect potrivite, un model pur lexical ar trebui să stea aproape de valoarea de hazard 0,50; un model sensibil la structură ar trebui să stea mult peste ea. Două controale apără interpretarea. Primul este un control al suprapunerii lexicale: pentru fiecare pereche raportăm suprapunerea Jaccard a mulțimilor de cuvinte ale celor doi membri, astfel încât o acurateță mare pe perechi bine potrivite să nu poată fi respinsă ca modelul mizând pe cuvinte diferite. Al doilea este comparația dintre o linie de bază lexicală și un model contextual: mărimea decisivă nu

este acuratețea absolută a vreunui model, ci marginea cu care modelul contextual depășește pe cel lexical pe perechi potrivite — marginea care, dacă este pozitivă și robustă, este dovada că contextul cumpără sensibilitate la structură.

3. Materiale și modele

Benchmark-ul a fost construit în trei etape și este publicat la toate trei. Un pilot de 24 de perechi (v0.1) a demonstrat metoda, dar era prea slab potrivit (Jaccard mediu între membri 0,21). Versiunea 0.2 l-a rescris ca 30 de perechi strâns potrivite (Jaccard 0,53). Versiunea 0.3, folosită pentru toate rezultatele de mai jos, îl extinde la 60 de perechi — zece pe fiecare tehnică — la o suprapunere Jaccard medie între membri de 0,50, deci aproximativ jumătate din cuvintele fiecărei perechi sunt împărțite între membrul manipulativ și cel de control. Două modele scorează fiecare membru. Linia de bază lexicală este modelul TF-IDF + regresie logistică din Lucrarea de lucru I (litere mici, unigrame și bigrame, prag de frecvență a documentelor, frecvență sublineară a termenilor, echilibrat pe clase). Modelul contextual este DistilBERT din Lucrarea de lucru II, ajustat fin pe partiția curată, disjunctă pe articole, a PropXplain. Fiecare model atribuie un scor de propagandă fiecăruia dintre cei 120 de membri; acuratețea pe pereche decurge direct.

4. Rezultate

4.1 Linia de bază lexicală este aproape de hazard; modelul contextual nu este

Pe cele 60 de perechi potrivite ca vocabular rezultatul este clar și indică o singură direcție. Linia de bază lexicală atinge o acuratețe pe pereche de 0,633 [IÎ 95% 0,51, 0,76] — doar puțin peste 0,50, cât ar obține un model care nu poate distinge structura — în timp ce transformerul ajustat fin atinge 0,917 [0,85, 0,99]. Cele două intervale de încredere nu se suprapun, deci marginea de aproximativ +0,28 este distinctă statistic, nu doar sugestivă. Tabelul 1 o descompune pe tehnici.

Tehnică	Perechi	Lexical	Transformer
presupoziție	10	1,00	1,00
echivalență fabricată	10	0,90	0,90
falsă dilemă	10	0,30	1,00
whataboutism	10	0,80	1,00
întrebare retorică încărcată	10	0,00	0,70
cauzalitate implicită	10	0,80	0,90
TOATE	60	0,633 [,51,,76]	0,917 [,85,,99]

Tabelul 1. Acuratețea pe pereche pe tehnici: membrul manipulativ a primit scor mai mare. Suprapunere Jaccard medie între membri 0,50. Hazardul este 0,50.

Mai grăitor decât numărul global este locul unde stă decalajul. Pe cele două tehnici unde linia de bază lexicală eșuează structural odată ce vocabularul este potrivit — întrebările retorice încărcate (linia de bază 0,00, transformerul 0,70) și falsa dilemă (0,30 la 1,00) — modelul contextual recuperează cea mai mare parte sau tot semnalul. Fiindcă cei doi membri ai fiecărei perechi împart majoritatea cuvintelor, acea recuperare nu poate fi atribuită vocabularului; este dovadă directă că modelul contextual este sensibil la structura retorică, afirmația pe care studiile la nivel de corpus nu au putut-o stabili. Acolo unde ambele modele reușesc deja (presupoziție, echivalență fabricată), indiciile din cuvintele simple sunt suficiente și cele două sunt de acord.

Fiindcă ambele modele au fost scorate pe aceleași șaizeci de perechi, comparația poate fi făcută ca un test pereche, nu ca două intervale separate. Analiza pereche este decisivă. Transformerul are dreptate pe nouăsprezece perechi pe care linia de bază le greșește, față de doar două perechi pe care linia de bază le nimerește iar transformerul le ratează (test McNemar exact, p = 0,0002); cele două modele au amândouă dreptate pe treizeci și șase de perechi și amândouă greșesc pe trei. Un interval de încredere bootstrap pe marginea pereche — acuratețea pe pereche a transformerului minus cea a liniei de bază, re-eșantionată pe perechi — este [+0,15, +0,42], excluzând zero. Avantajul nu este, prin urmare, un artefact al două intervale de încredere care se întâmplă să nu se atingă; este o diferență pereche semnificativă pe aceleași perechi.

4.2 Marginea este stabilă pe semințele de antrenament

O singură rulare de antrenament ar putea fi norocoasă. Transformerul a fost, prin urmare, reantrenat de cinci ori, ținând partiția de date fixă și variind doar inițializarea modelului și ordinea datelor; fiecare rulare a scorat aceleași 60 de perechi. Tabelul 2 raportează cele cinci acurateți pe pereche.

Sămânță	Acuratețe pe pereche	vs. linia de bază 0,633
13	0,833	peste
21	0,900	peste
42	0,917	peste
101	0,867	peste
202	0,883	peste
medie	0,880 (ab. std. 0,032)	Î 95% [0,852, 0,908]

Tabelul 2. Acuratețea pe pereche a transformerului pe cinci semințe de antrenament, partiție fixă. Fiecare sămânță depășește linia de bază lexicală; intervalul între semințe o exclude.

Fiecare sămânță în parte stă mult peste linia de bază lexicală, iar intervalul de încredere 95% între semințe [0,852, 0,908] o exclude în întregime, deci marginea este o proprietate stabilă a modelului contextual, nu un accident de inițializare. Ierarhia pe tehnici este și ea stabilă între semințe: falsa dilemă, cauzalitatea implicită, presupoziția și echivalența fabricată au o medie de 0,92 până la 0,96, în timp ce întrebarea retorică încărcată rămâne cea mai slabă, la 0,62 (interval 0,50 până la 0,70) — singurul loc unde diferența reziduală de formulare a controlului încă îl costă pe model.

4.3 Un evaluator independent recuperează etichetele

Perechile și etichetele lor manipulativ/control au fost scrise de autor. Pentru a verifica dacă nu sunt doar judecata privată a unei singure persoane, un evaluator independent care nu a luat parte la construcția lor — un model de limbaj separat, OpenAI gpt-4o-mini — a etichetat orb fiecare propoziție. Cei 120 de membri au fost amestecați astfel încât nicio pereche să nu fie văzută alăturat, iar fiecare a fost judecat singur ca manipulativ sau simplu. Tabelul 3 rezumă acordul.

Evaluator independent (gpt-4o-mini), orb	Valoare
Acord brut pe membru cu etichetele autorului	80,8% (97/120)
Kappa Cohen	0,617 (substanțial)
Recuperare pe manipulativ (sensibilitate)	0,85
Recuperare pe control (specificitate)	0,77
Alegere forțată pe pereche (alege manipulativul autorului)	55/60 = 0,917

Tabelul 3. Acordul unui evaluator model independent și orb cu etichetele autorului. Banda kappa după Landis & Koch (1977).

Un model din afară, orb față de construcție, recuperează distincția manipulativ/simplu mult peste hazard (kappa Cohen 0,617, în banda substanțială a lui Landis & Koch, 1977), deci etichetele nu sunt judecata privată a unei singure persoane. Acesta este un evaluator model, nu unul uman, și este raportat ca atare: întărește etichetele, nu le certifică. Dezacordurile lui sunt structurate, nu aleatorii, și întăresc constructul în loc să-l submineze. Cele paisprezece alarme false ale evaluatorului — un control numit manipulativ — cad în mare parte pe echivalența fabricată, unde controlul păstrează cuvinte încărcate („dictatură", „hoț") care ademenesc un model care mizează pe vocabular; cele nouă ratări — un manipulativ numit simplu — sunt toate presupoziții, procedeul cel mai subtil, greu de văzut într-o propoziție citită izolat. Esențial, acestea nu sunt tehnicile la care au eșuat detectoarele: linia de bază lexicală a eșuat la întrebările retorice încărcate și la falsa dilemă, în timp ce evaluatorul independent este perfect la amândouă și se poticnește altundeva. Faptul că eșecurile se mută după tehnică, de la evaluator la evaluator, este el însuși dovadă că perechile sondează structuri retorice distincte, nu un singur artefact de vocabular pe care orice model l-ar prinde sau rata la fel.

4.4 Marginea transformerului nu urmărește vocabularul; succesul liniei de bază o face

Fiindcă perechile sunt potrivite dar nu identice ca vorbe (Jaccard mediu 0,50), un sceptic poate încă susține că modelul contextual câștigă pe diferența reziduală de vocabular. Scorurile deja disponibile testează asta direct. Dacă transformerul ar exploata cuvintele rămase, avantajul lui ar crește pe măsură ce cei doi membri se îndepărtează lexical — ar câștiga cel mai mult pe perechile slab potrivite și s-ar poticni unde cuvintele sunt aproape identice. Se întâmplă contrariul. Marginea de scor a transformerului este practic necorelată cu suprapunerea lexicală (Pearson $r = +0{,}04$, $p = 0{,}75$), iar acuratețea lui pe pereche este, dacă e ceva, ușor mai mare pe jumătatea bine potrivită (0,93, Jaccard peste mediană) decât pe jumătatea slab potrivită (0,83) — inversul a ceea ce ar arăta un model care exploatează vocabularul. Ca și control, linia de bază lexicală se comportă exact cum ar trebui un model lexical: corectitudinea ei este semnificativ corelată cu suprapunerea (r punct-biserial $= +0{,}50$, $p < 0{,}001$), urcând de la 0,43 pe perechile slab potrivite la 0,83 pe cele bine potrivite. Pe submulțimea cu suprapunere mare (Jaccard ≥ 0,60, douăzeci de perechi, unde aproape toate cuvintele sunt împărțite), ambele modele obțin scoruri mari (transformerul 0,93, linia de bază 0,90), așa cum e de așteptat când rămân doar câteva cuvinte structurale care să poarte semnalul. Tiparul pe întregul interval este cel informativ: succesul modelului lexical depinde de cât vocabular distinge membrii, iar al modelului contextual nu depinde. Aceasta este dovadă directă că marginea transformerului provine din structura retorică, nu din vocabularul rămas nepotrivit.

5. Discuție

Patru linii independente converg. Pe vocabular potrivit, un model lexical stă aproape de hazard, iar unul contextual nu; decalajul supraviețuiește reantrenării pe cinci semințe; un evaluator din afară, orb față de design, recuperează aceeași distincție cu acord substanțial; și marginea modelului contextual, spre deosebire de succesul celui lexical, nu urmărește diferența reziduală de vocabular a perechilor. Împreună, acestea susțin o afirmație îngustă dar reală: pe acest instrument, modelul contextual este sensibil la structura retorică, nu doar la vocabular, iar distincția manipulativ/simplu pe care o codifică perechile este recuperabilă de un evaluator care nu a văzut niciodată cum au fost construite. Este tocmai afirmația pe care o evaluare făcută pe corpusul de antrenament nu o poate face, fiindcă acolo structura și vocabularul sunt confundate. Este, de asemenea, afirmația de care are nevoie un strat de audit defensiv înainte de a putea fi de încredere: un instrument care semnalează manipularea ar trebui să răspundă la manipulare, nu la un vocabular care se întâmplă să o însoțească.

Afirmația este deliberat modestă ca domeniu. Acuratețea pe pereche măsoară sensibilitatea la structura retorică cu vocabularul ținut aproape fix; nu măsoară dacă un pasaj „este propagandă” în vreun sens politic sau juridic, dacă ar convinge o audiență reală sau dacă constructul „manipulare” este operaționalizat valid pe deplin. O acuratețe mare pe pereche este dovadă că un model reprezintă o structură; nu este dovadă că modelul, ori etichetele de corpus pe care a fost antrenat, surprind manipularea așa cum operează ea în lume. Validitatea de construct se câștigă treptat — tehnică cu tehnică, evaluator cu evaluator — iar această lucrare raportează o etapă, nu un verdict.

6. Limite

Patru limite mărginesc rezultatul și sunt enunțate deschis, fiindcă credibilitatea programului se sprijină pe delimitarea onestă. Întâi, verificarea independentă este un model, nu un om; un adnotator uman și un acord între evaluatori umani rămân dovada mai puternică și pasul următor firesc, iar acordul substanțial-dar-imperfect al evaluatorului model (kappa 0,617) arată că etichetele sunt apărabile, nu stabilite definitiv. În al doilea rând, suprapunerea medie între membri este 0,50 — substanțială, dar nu identitate — deci rămâne un reziduu de diferență de vocabular, concentrat pe întrebările retorice încărcate a căror formulare de control („oamenii se întreabă dacă …”) diferă ca formă; tehnica cea mai slabă este exact cea unde acel reziduu este cel mai mare. În al treilea rând, perechile sunt stimuli construiți de autor, nu text apărut natural; ele izolează structura prin design, ceea ce este scopul lor, dar succesul unui model pe ele nu garantează aceeași sensibilitate pe pasaje reale, dezordonate. În al patrulea rând, modelul contextual este un singur transformer de dimensiune modestă antrenat pe un singur corpus; rezultatul arată că contextul poate cumpăra sensibilitate la structură aici, nu că transformerele „detectează manipularea” în general.

7. Notă etică

Acest instrument scorează structura retorică. Nu trebuie folosit niciodată pentru a decide care poziții politice sunt legitime. O falsă dilemă sau o întrebare retorică încărcată poate sluji orice cauză; detectarea procedeului nu spune nimic despre adevărul sau valoarea poziției pe care o avansează. Scopul defensiv al programului mai larg — de a măsura și explica manipularea, nu de a ierarhiza vorbitori sau de a suprima discursul — depinde de păstrarea acestei linii clare. Publicat deschis, benchmark-ul este la fel de disponibil celor care ar audita punctele oarbe ale unui detector ca și celor care ar construi unul, ceea ce este echilibrul intenționat pentru un instrument diagnostic.

8. Concluzie și materiale deschise

Un instrument diagnostic cu perechi contrastive separă sensibilitatea la structură de un corelat lexical într-un mod în care evaluarea la nivel de corpus nu o poate face. Pe șaizeci de perechi potrivite ca vocabular, o linie de bază lexicală stă aproape de hazard (0,633), iar un transformer contextual nu (0,917, intervale care nu se suprapun, test pereche McNemar p = 0,0002); marginea este stabilă pe cinci semințe (medie 0,880, IÎ 95% [0,852, 0,908]); un evaluator orb independent recuperează etichetele autorului cu acord substanțial (kappa 0,617); iar marginea modelului contextual, spre deosebire de succesul celui lexical, nu urmărește vocabularul rezidual. Instrumentul este oferit ca diagnostic cu materiale complet deschise, nu ca o măsură validată a manipulării, iar limitele lui îi definesc foaia de parcurs: adnotare umană, formulare mai strânsă a controlului pe tehnicile cele mai slabe și testare pe text apărut natural. Toate materialele — cele trei seturi de perechi, utilitarul de scorare, scorurile pe membru pentru linia de bază și pentru fiecare sămânță a transformerului, judecățile oarbe ale evaluatorului independent, utilitarul multi-sămânță și întregul protocol — sunt publicate în depozit pentru ca alții să le poată inspecta, critica și extinde.

Referințe

Cohen, J. (1960). A coefficient of agreement for nominal scales. Educational and Psychological Measurement, 20(1), 37–46.

Cronbach, L. J., & Meehl, P. E. (1955). Construct validity in psychological tests. Psychological Bulletin, 52(4), 281–302.

Da San Martino, G., Barrón-Cedeño, A., Wachsmuth, H., Petrov, R., & Nakov, P. (2020). SemEval-2020 Task 11: Detection of propaganda techniques in news articles. Proceedings of the 14th Workshop on Semantic Evaluation, 1377–1414.

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1), 159–174.

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108.

Șerban, G. F. (2026). Detecting Political Manipulation as a Defensive Practice: A Leakage-Corrected Lexical Baseline (Working Paper I). Zenodo. https://doi.org/10.5281/zenodo.23884579

Șerban, G. F. (2026). At Equal Review Cost, Context Helps (Working Paper II). Zenodo. https://doi.org/10.5281/zenodo.23884579